
ANÁLISIS DE DATOS GEOESPACIALES: APLICACIÓN A LA SINIESTRALIDAD VIAL EN MADRID

GEOSPATIAL DATA ANALYSIS: APPLICATION TO ROAD ACCIDENTS IN MADRID

TRABAJO DE FIN DE GRADO

Autor:

Jorge García de Lorenzo

Director:

Fernando Reche Lorite

GRADO EN MATEMÁTICAS



JULIO, 2025

Universidad de Almería

Índice general

Índice de figuras	III
Abstract	V
Resumen	VI
1 Introducción	1
1.1. Ámbito de los datos	1
1.2. Objetivos	2
Objetivos Específicos, 3.	
2 Marco Teórico y Fundamentos del Análisis Espacial	5
2.1. El Problema Geométrico de la Cartografía	5
Herramientas Fundamentales, 5.— Imposibilidad de un Mapa Perfecto, 6.	
2.2. Fundamentos de Datos y Estructuras Geoespaciales	7
Definición y Tipos de Datos Geoespaciales, 7.— Indices Espaciales (Spatial Indexes), 7.	
2.3. Métodos de Análisis Espacial	8
Análisis de Proximidad: Diagramas de Voronoi, 8.— Análisis de Accesibilidad: Isolíneas, 9.— Análisis de Clustering, 10.	
2.4. Estadística Espacial para la Detección de Patrones y Relaciones	13
Autocorrelación Espacial Global: El I de Moran, 14.— Detección de Patrones Locales: Indicadores Locales de Asociación Espacial (LISA), 14.— Análisis de Relaciones: Regresión Geográficamente Ponderada (GWR), 16.	
3 Metodología y Diseño Experimental	17
3.1. Visión General del Flujo de Trabajo y Herramientas	17
3.2. Fuentes de Datos y Adquisición	17
3.3. Fase 1: Preprocesamiento de Datos con R	18
3.4. Fase 2: Visualización Analítica con Tableau	19
Diseño y Creación de Dashboards, 19.	
3.5. Fase 3: Modelado y Análisis Espacial con CARTO Workflows	20
Workflow 1: Enriquecimiento de Datos y Muestreo, 20.— Workflow 2: Análisis de Áreas de Influencia con Diagramas de Voronoi, 22.— Workflow 3: Comparación de Isócronas e Isodistancias, 23.— Workflow 4: Desarrollo del Perfil de Riesgo Hospitalario, 24.— Workflow 5: Detección de Clústeres Espaciales (LISA), 26.— Workflow 6: Identificación de Puntos Negros con DBSCAN, 27.	
3.6. Fase 4: Diseño de Mapas Analíticos con CARTO Builder	28
4 Resultados y Análisis	29
4.1. Análisis Exploratorio de Patrones con Tableau	29
Dashboard 1: Panel de Control y Proyección de Accidentalidad, 29.— Dashboard 2: Accidentes: Distribución Geográfica y Anual, 30.— Dashboard 3: Accidentes: Patrones Diarios, Horarios y Tipología, 31.— Dashboard 4: Implicados: Visión General, Lesividad y Rol, 31.— Dashboard 5: Análisis Detallado de Severidad, 32.— Dashboard 6: Perfil del Conductor Implicado, 33.— Dashboard 7: Conductores: Consumo de Sustancias y Fatalidades,	

34.	
4.2. Resultados del Modelado Espacial con CARTO	34
Panorámica de la Concentración: Análisis de Clústeres, 35.— Cobertura Sanitaria Teórica: Análisis de Voronoi, 36.— Síntesis 3D: Análisis Multidimensional de Riesgo y Cobertura, 37.— Validación Estadística: Detección de Hotspots y Clústeres con LISA, 39.— Diagnóstico de Precisión: Identificación del “Efecto Arterial” a Escala H10, 41.— Análisis de Puntos Negros: Detección de Clústeres de Alta Densidad con DBSCAN, 42.	
5 Discusión, Conclusiones y Líneas Futuras	45
5.1. Discusión de Resultados	45
5.2. Conclusiones Principales	46
5.3. Líneas Futuras de Investigación	46
Bibliografía	49
Apéndices	51
A Código y Campos Calculados	53
A.1. Script de Preprocesamiento en R	53
A.2. Scripts SQL de Workflows de CARTO	59
Workflow de Accidentalidad, 59.— Workflow de Voronoi, 67.— Workflow de Comparación de Isolíneas, 72.— Workflow de Perfil de Riesgo de Hospitales, 76.— Workflow de Análisis de Autocorrelación Espacial (LISA), 88.— Workflow de Generación de Polígonos de Clústeres DBSCAN, 93.	
A.3. Campos Calculados de Tableau	96
B Diccionario de Variables	99
B.1. Ficheros de Datos de Accidentalidad	99
B.2. Fichero: distritos.geojson	101
B.3. Fichero: hospitales.geojson	102
B.4. Fichero: radares_fijos.geojson	102
B.5. Fichero: camaras.geojson	103
C Visualizaciones Complementarias	105
C.1. Ejemplos de Proyecciones Cartográficas	105

Índice de figuras

2.1. Propiedades fundamentales de H3. Izquierda: Relación jerárquica padre-hijo. Derecha: Ilustración de la función K-Ring para identificar vecinos. Adaptado de [McK22].	8
2.2. Ejemplo canónico de un diagrama de Voronoi.	9
2.3. Comparativa visual de una isócrona de 10 min (azul) y una isodistancia de 2.5 km (marrón) para el Hospital La Paz.	10
2.4. Diferencia conceptual entre Getis-Ord G_i^* y el I de Moran Local.	16
2.5. Representación conceptual de un cubo espacio-temporal.	16
3.1. Diagrama del workflow de CARTO para el enriquecimiento y muestreo de los datos de accidentalidad.	20
3.2. Diagrama del workflow de CARTO para el análisis de áreas de servicio con Diagramas de Voronoi.	22
3.3. Diagrama del workflow utilizado para la comparación metodológica de isolíneas.	24
3.4. Diagrama del workflow de CARTO para la creación del perfil de riesgo basado en isócronas y H3.	25
3.5. Workflow de CARTO para el análisis de autocorrelación espacial (LISA) a resolución H9.	27
3.6. Workflow de CARTO para la identificación y caracterización de puntos negros con DBSCAN.	28
4.1. Panel de Control y Proyección de Accidentalidad.	29
4.2. Accidentes: Distribución Geográfica y Anual.	30
4.3. Accidentes: Patrones Diarios, Horarios y Tipología.	31
4.4. Implicados: Visión General, Lesividad y Rol.	32
4.5. Análisis Detallado de Severidad: Factores y Grupos.	32
4.6. Perfil del Conductor Implicado.	33
4.7. Conductores: Consumo de Sustancias y Consecuencias Fatales.	34
4.8. Mapa de clústeres que muestra la concentración de accidentes en Madrid. Explorar el mapa interactivo en CARTO.	35
4.9. Diagrama de Voronoi de los hospitales de Madrid, mostrando las áreas teóricas de servicio. Explorar el mapa interactivo en CARTO.	36
4.10. Mapa 3D de Severidad vs. Cobertura. La altura representa el número de accidentes graves/fatales y el color, el tiempo de respuesta hospitalaria. Explorar el mapa interactivo en CARTO.	38
4.11. Mapa 3D de Riesgo Peatonal vs. Cobertura. La altura representa el número de atropellos y el color, el tiempo de respuesta. Explorar el mapa interactivo en CARTO.	38
4.12. Resultados brutos del análisis LISA. Izquierda: Getis-Ord G_i^* . Derecha: Local Moran's I. Explorar el mapa interactivo en CARTO.	40
4.13. Resultados del análisis LISA filtrados por significancia estadística ($p < 0.05$). Explorar el mapa interactivo en CARTO.	40
4.14. Resultados brutos del análisis LISA a resolución H10. La limitación computacional impide la validación del Local Moran's I. Explorar el mapa interactivo en CARTO.	41

4.15. Hotspots de accidentalidad estadísticamente significativos ($p < 0.05$) a resolución H10. El enlace interactivo corresponde al mapa de la Figura 4.14, aplicando un filtro de $p_value < 0.05$	42
4.16. Clústeres de alta densidad (“puntos negros”) identificados con DBSCAN. Cada polígono representa una intersección o nudo vial con una concentración extrema de accidentes. Explorar el mapa interactivo en CARTO	43
C.1. La proyección de Mercator, un ejemplo de proyección conforme . Preserva los ángulos y las formas locales, pero distorsiona masivamente las áreas. Obsérvese cómo Groenlandia (2.16 millones de km^2) parece tener un tamaño similar al de África (30.37 millones de km^2), cuando en realidad África es 14 veces más grande.	105
C.2. La proyección de Gall-Peters, un ejemplo de proyección equivalente (isareal). Preserva la proporción correcta de las áreas, mostrando el tamaño real de los continentes entre sí. Sin embargo, para lograrlo, distorsiona notablemente sus formas, especialmente en las zonas ecuatoriales y polares, que aparecen estiradas vertical u horizontalmente.	106

Abstract

The increasing availability of geospatial data offers an unprecedented opportunity to analyze and understand complex urban phenomena such as road accidents. This Final Degree Project undertakes a comprehensive analysis of traffic accidents in the city of Madrid for the period 2019- the first quarter of 2025, aiming to identify spatial patterns, risk factors, and areas of vulnerability.

The methodology combines rigorous data preprocessing in R with advanced analysis and visualization techniques on Location Intelligence (CARTO) and Business Intelligence (Tableau) platforms. Methods of proximity analysis (Voronoi Diagrams), accessibility (Isochrones), and spatial aggregation (H3 Index) were applied. Furthermore, spatial statistics techniques, such as the Getis-Ord G_i^* and Local Moran's I statistics, were used to validate the existence of accident clusters.

The results reveal a strong spatial autocorrelation, with a massive concentration of accidents in the city's central core, which contrasts with a low incidence in the periphery. A 3D multidimensional analysis demonstrated a "density paradox": the areas with the highest risk of severe accidents and pedestrian-involved incidents coincide with the areas enjoying the best healthcare coverage in terms of response time. Likewise, specific critical points were identified in the periphery where moderate risk combines with poorer hospital accessibility.

In conclusion, this work not only quantifies and locates road risk in Madrid with high resolution but also proposes a dual intervention strategy: prevention policies (traffic calming, pedestrian protection) in the city center, and emergency response optimization in the vulnerable peripheral arc.

Keywords: geospatial data analysis, road accidents, location intelligence, CARTO, H3, hotspot analysis, LISA, data visualization.

Resumen

La creciente disponibilidad de datos geoespaciales ofrece una oportunidad sin precedentes para analizar y comprender fenómenos urbanos complejos como la siniestralidad vial. Este Trabajo Fin de Grado aborda un análisis exhaustivo de los accidentes de tráfico en la ciudad de Madrid durante el periodo 2019-1er. cuatrimestre 2025, con el objetivo de identificar patrones espaciales, factores de riesgo y áreas de vulnerabilidad.

La metodología empleada combina preprocesamiento de datos en R con técnicas avanzadas de análisis y visualización en plataformas de Inteligencia de Localización (CARTO) y de Negocio (Tableau). Se aplican métodos de análisis de proximidad (Diagramas de Voronoi), de accesibilidad (Isócronas) y de agregación espacial (Índice H3). Además, se utilizan técnicas de estadística espacial, como los estadísticos Getis-Ord G_i^* y Local Moran's I, para validar la existencia de clústeres de siniestralidad.

Los resultados revelan una fuerte autocorrelación espacial, con una masiva concentración de accidentes en el núcleo central de la ciudad, que contrasta con una baja incidencia en la periferia. Un análisis multidimensional 3D demostró la existencia de una “paradoja de la densidad”: las zonas con mayor riesgo de accidentes graves y de atropellos coinciden con las áreas de mejor cobertura sanitaria en términos de tiempo de respuesta. Asimismo, se identificaron puntos críticos específicos en la periferia donde un riesgo moderado se combina con una peor accesibilidad hospitalaria.

En conclusión, este trabajo no solo cuantifica y localiza el riesgo vial en Madrid con una alta resolución, sino que propone una estrategia de intervención dual: políticas de prevención (reducción de la velocidad, protección peatonal) en el centro y de optimización de la respuesta de emergencia en el arco periférico vulnerable.

Palabras clave: análisis de datos geoespaciales, siniestralidad vial, inteligencia de localización, CARTO, H3, análisis de hotspots, LISA, visualización de datos.

Introducción

El análisis de datos se ha convertido en una herramienta fundamental para la toma de decisiones en múltiples aspectos de nuestras vidas, sobre todo a nivel profesional. Desde el ámbito empresarial privado hasta la gestión urbana realizada por las diferentes Administraciones, la capacidad de extraer conocimientos de importantes volúmenes de datos siempre nos va a permitir mejorar en nuestros procesos y ser más eficientes en la utilización de los limitados recursos.

Este Trabajo Fin de Grado en Matemáticas, consiste en llevar a cabo un análisis de datos, en el que añadimos al propio análisis el valor de lo que se conoce como “location intelligence”, una inteligencia sacada del conocimiento de la ubicación. Esto es posible gracias a la utilización de datos en los que hay variables con coordenadas geoespaciales.

Las diferentes partes del análisis que podemos identificar como conjuntos de datos, depuración y limpieza, modelos aplicados, análisis desarrollado y visualización de resultados son todas igual de importantes, y el éxito de unas conclusiones válidas en un trabajo de análisis depende del equilibrio existente en el grado de importancia que demos a cada una de ellas. Si en un trabajo nos volcamos en exceso en la importancia de un aspecto en detrimento de la importancia de algún otro, podemos asegurar que el resultado obtenido con el trabajo será muy pobre. La experiencia en muchos de los trabajos ya publicados es lo que nos indica, y trataremos de no caer en dicho error.

Por este motivo, y a pesar de ser un trabajo del Grado en Matemáticas, donde hay una parte importante de desarrollo con el análisis matemático apoyado en unos modelos estadísticos utilizados, el lector no debe pasar por encima otros aspectos. Tenemos que dar la importancia que requiere el estudio de mercado que se esconde tras la justificación de la elección de datos, el tiempo empleado tras las tareas de depuración de datos, los criterios escogidos y el desarrollo realizado en la limpieza de datos, y, finalmente, las pruebas realizadas con las herramientas de visualización hasta llegar a elegir unos ejemplos apropiados para la presentación de resultados. Todo eso debe ponerse en valor a la hora de leer y comprender este trabajo, y no únicamente los aspectos estadísticos de las matemáticas que incorpora.

Este trabajo abarca el análisis de datos desde dos puntos de vista:

- **Desarrollos matemáticos**, con procesamientos realizados en R y con scripts de SQL insertados en los workflows de CARTO, buscando conseguir los objetivos de este trabajo.
- **Visualización de resultados**, en el que se muestren los resultados con gráficos y mapas, realizados en Tableau y CARTO.

1.1 *Ámbito de los datos*

La elección de los conjuntos de datos para realizar el análisis es el punto de partida, y de la calidad y cantidad de los datos dependerá conseguir nuestros objetivos.

Tener una cantidad importante de datos distribuidos a lo largo de una larga serie nos permitirá tener unas predicciones con mayor posibilidad de acierto. La búsqueda de patrones y su utilización posterior junto a los modelos matemáticos nos darán una inferencia con mejores resultados.

Dentro de la amplia variedad de tipos de datos existentes actualmente en el conjunto de internet, los que tienen mayor facilidad de acceso son los que facilitan los organismos públicos. Desde hace ya unos años, las diferentes administraciones de muchos países suelen poner a disposición en sus páginas web diversos conjuntos de datos correspondientes a alguna rama de sus gestiones.

Las empresas privadas con sus datos, excepto si tienen una obligación legal de publicarlos, o si les interesa por demostrar la buena marcha actual del negocio, no suelen darlos a conocer. Es cierto que en algunos casos se obtienen datos para que los clientes puedan ver lo bien que funciona una línea aérea o para ver la eficiente gestión que se lleva a cabo en las reclamaciones por averías de una marca de coches.

Con el párrafo anterior se está dando la justificación de volcarnos en la búsqueda de datos en las empresas públicas y más concretamente en Administraciones Públicas.

Los conjuntos de datos pueden contener datos de múltiples aspectos de la vida ciudadana, pero debemos decantarnos por alguno en el que el sesgo proveniente de la manipulación sea menor.

Después de analizar múltiples conjuntos de datos de diversos ámbitos y con multitud de variables, en este proyecto nos hemos decantado por el registro de los accidentes de tráfico que ocurren a lo largo del año. Los accidentes de tráfico son sucesos que ocurren en nuestras vidas debido a nuestra actual manera de vivir, de movernos para ir a trabajar o para ir al colegio, de desplazarnos en las vacaciones, etc.

Vamos ahora con el punto más importante de la elección del ámbito de los datos. Dentro de las variables que se pueden analizar en los datos de accidentalidad, intervienen muchos grupos de trabajo, policía local, guardia civil, bomberos, ambulancias y hospitales, seguros de vehículos, etc. Cuando se tienen que generar los datos relativos a un accidente entran en juego muchas personas, por lo tanto, es más fácil tener un control de la veracidad de los datos, ya que siempre es más complicado falsear algo cuanto tienen que hacerlo un montón de personas. Este es el principal motivo por el que la elección de datos de accidentalidad creemos que es acertada.

En otros trabajos, con conjuntos de datos de diferentes aspectos (cambio climático, registro de parados, etc.) los resultados que se obtengan pueden tener un mayor índice de duda en su acercamiento a la realidad.

Una vez que hemos decidido el ámbito de accidentalidad para los datos, tenemos que decidir cuál es al alcance de dichos datos: a nivel de toda España, a nivel de una comunidad o una provincia, o a nivel de un municipio. Dentro del ámbito Administración General, Comunidades Autónomas y Ayuntamientos, nos hemos decidido finalmente por el Ayuntamiento de Madrid, que es uno de los municipios con series más largas en el tiempo y más numerosas en cuanto a número de registros.

1.2 *Objetivos*

En este proyecto vamos a trabajar con los datos de accidentalidad de los últimos años en la ciudad de Madrid, junto con los datos de ubicación de los hospitales, las cámaras, los radares y los distritos de la ciudad de Madrid para lograr los siguientes objetivos:

- Estudiar la gravedad de los accidentes: Teniendo en cuenta el número de víctimas y las cifras de asistencia en hospitales, se puede valorar cuantitativamente la

gravedad de los accidentes, analizar las consecuencias y priorizar determinadas acciones preventivas.

- Estudiar los tipos de accidentes: Conociendo los tipos de accidentes, teniendo en cuenta los atropellos, colisiones, vehículos implicados, condiciones del clima, tipo de vía, podemos implementar medidas específicas que disminuyan el número de accidentes.
- Analizar la distribución de accidentes en Madrid a lo largo de los últimos años.
- Identificar patrones: Conociendo la frecuencia de accidentes en diferentes zonas, días de la semana y horas del día, podemos identificar zonas y momentos de mayor riesgo.
- Identificar relaciones: Entre la accidentalidad y variables con peso, entre gravedad del accidente y asistencia en hospital por la proximidad a hospitales.
- Localización: Estudiar las correlaciones entre esas localizaciones y variables como el tipo de vía y la densidad de tráfico.
- Visualizar tendencias: Realizando un análisis comparativo a lo largo de los años, podemos mostrar la evolución de la seguridad vial con el tiempo.
- Proponer recomendaciones basadas en los hallazgos del análisis que puedan contribuir a la gestión del riesgo urbano.

Objetivos Específicos

- Preparar y limpiar el conjunto de datos de accidentes de tráfico de Madrid.
- Realizar un análisis exploratorio de datos (EDA) utilizando herramientas de visualización como Tableau y CARTO.
- Aplicar y evaluar la utilidad de índices espaciales como H3 para la agregación y análisis de datos de accidentes.
- Implementar métodos de autocorrelación espacial (I de Moran Local, Getis-Ord Gi*) para identificar clusters y puntos calientes/fríos de accidentalidad.
- Identificar y caracterizar “puntos negros” de alta densidad de siniestralidad mediante algoritmos de clustering basados en densidad (DBSCAN).
- Explorar relaciones espaciales mediante Regresión Geográficamente Ponderada (GWR).
- Documentar los procesos y presentar los resultados de forma clara.

Marco Teórico y Fundamentos del Análisis Espacial

Este capítulo sienta las bases teóricas que sustentan el presente trabajo. Se inicia abordando el problema geométrico fundamental de la cartografía para comprender las limitaciones inherentes a cualquier representación plana de la Tierra. A continuación, se definen las estructuras de datos y los sistemas de indexación que permiten un manejo computacionalmente eficiente. Finalmente, se presenta el conjunto de técnicas de análisis y estadística espacial que se emplearán para la detección de patrones, la segmentación por clústeres y el modelado de relaciones en los datos de siniestralidad.

2.1 El Problema Geométrico de la Cartografía

Este trabajo se apoya en la formulación geométrica del problema cartográfico según la teoría de superficies de do Carmo [dC16]. El objetivo es mostrar que no puede existir una proyección localmente isométrica de la esfera sobre el plano.

Herramientas Fundamentales

Definición 2.1 (Primera Forma Fundamental). La **Primera Forma Fundamental** de una superficie regular $S \subset \mathbb{R}^3$ en un punto $p \in S$ es la forma cuadrática $I_p : T_p S \rightarrow \mathbb{R}$ definida, para todo vector $w \in T_p S$, por la expresión:

$$I_p(w) := \langle w, w \rangle_p = \|w\|^2 \geq 0. \quad (2.1)$$

La Primera Forma Fundamental es la métrica intrínseca de la superficie. Si $X(u, v)$ es una parametrización de un entorno de p , los coeficientes de su matriz asociada en la base $\{X_u, X_v\}$ son $E = \langle X_u, X_u \rangle$, $F = \langle X_u, X_v \rangle$ y $G = \langle X_v, X_v \rangle$. A partir de ellos se puede calcular la longitud de una curva, el ángulo entre dos curvas y el área de una región.

Definición 2.2 (Aplicación de Gauss). Sea $S \subset \mathbb{R}^3$ una superficie orientable. La aplicación $N : S \rightarrow \mathbb{S}^2$ asigna a cada punto $p \in S$ su vector normal unitario $N(p)$, que es un punto en la esfera unidad $\mathbb{S}^2$. Esta aplicación N se denomina la **aplicación de Gauss** de la superficie S .

La curvatura de Gauss mide cómo esta aplicación de Gauss distorsiona la superficie.

Definición 2.3 (Curvatura de Gauss). Sea $p \in S$ y sea $dN_p : T_p(S) \rightarrow T_p(S)$ la diferencial de la aplicación de Gauss. El determinante de dN_p es la **curvatura gaussiana** K de S en p .

- La **esfera** de radio R , $\mathbb{S}^2$, tiene curvatura de Gauss constante y positiva: $K = 1/R^2 > 0$.
- El **plano euclídeo** $\mathbb{R}^2$ es una superficie plana, con curvatura de Gauss nula en todos sus puntos: $K = 0$.

Definición 2.4 (Isometría Local). Una aplicación diferenciable $f : S_1 \rightarrow S_2$ entre superficies es una **isometría local** en $p \in S_1$ si su diferencial df_p preserva la primera forma fundamental: es decir, para todo $v \in T_p S_1$,

$$\langle df_p(v), df_p(v) \rangle_{f(p)} = \langle v, v \rangle_p.$$

Definición 2.5 (Aplicación Conforme). Un difeomorfismo $f : S_1 \rightarrow S_2$ es **conforme** si para todo $p \in S_1$ y para cualesquiera $v_1, v_2 \in T_p S_1$ se tiene que:

$$\langle df_p(v_1), df_p(v_2) \rangle_{f(p)} = \lambda^2(p) \langle v_1, v_2 \rangle_p,$$

donde $\lambda^2(p)$ es una función diferenciable no nula.

Geoméricamente, esto significa que las aplicaciones conformes **preservan los ángulos** entre curvas, aunque no necesariamente las distancias.

Teorema 2.1 (Teorema Egregium de Gauss). La curvatura de Gauss $K(p)$ de una superficie es un invariante ante isometrías locales.

Este resultado nos dice que la curvatura de Gauss depende únicamente de la Primera Forma Fundamental y sus derivadas. En consecuencia, si $f : S_1 \rightarrow S_2$ es una isometría local, entonces $K_{S_1}(p) = K_{S_2}(f(p))$ para todo $p \in S_1$.

Imposibilidad de un Mapa Perfecto

Corolario 2.1. No existe ningún mapa perfecto (localmente isométrico) entre un abierto de la esfera S^2 y un abierto del plano $\mathbb{R}^2$.

Demostración:

Supongamos que $f : \Omega \subset S^2(R) \rightarrow \Delta \subset \mathbb{R}^2$ es una isometría local. Por el Teorema Egregium, se preserva la curvatura de Gauss:

$$K_{S^2}(p) = K_{\mathbb{R}^2}(f(p)) \quad \forall p \in \Omega.$$

Pero $K_{S^2} = 1/R^2 > 0$, mientras que $K_{\mathbb{R}^2} = 0$. Contradicción. Por tanto, tal isometría no puede existir. ■

La imposibilidad de un mapa perfecto nos obliga a aceptar que toda proyección cartográfica introduce distorsiones. La elección de una proyección implica decidir qué propiedades geométricas se preservarán a costa de distorsionar otras. Esto da lugar a la clasificación fundamental de las proyecciones, que representan diferentes tipos de compromiso:

- **Proyecciones Conformes:** Preservan los ángulos locales. Son ideales para la navegación, ya que una ruta de rumbo constante (loxodrómica) se representa como una línea recta. El ejemplo más famoso es la **proyección de Mercator**. Su principal desventaja es la severa distorsión de las áreas a altas latitudes, como se ilustra en el Apéndice C, Figura C.1.

- **Proyecciones Isoareales:** Preservan el área. Son cruciales para la cartografía temática y estadística, ya que garantizan que las comparaciones de tamaño entre regiones sean válidas. Un ejemplo notable es la **proyección de Gall-Peters**, que mantiene la proporción correcta de las áreas de los continentes, pero a costa de distorsionar visiblemente sus formas. Una ilustración de este efecto se puede ver en el Apéndice C, Figura C.2.

2.2 Fundamentos de Datos y Estructuras Geoespaciales

Definición y Tipos de Datos Geoespaciales

Los datos geoespaciales son aquellos que describen objetos, eventos o fenómenos que tienen una ubicación en la superficie terrestre. Se pueden clasificar principalmente en dos tipos primitivos:

- **Datos Vectoriales:** Representan características geográficas discretas mediante puntos, líneas y polígonos. En este trabajo, los accidentes, hospitales y radares se tratan como datos puntuales, mientras que los distritos se representan como polígonos.
- **Datos Ráster:** Consisten en una rejilla regular de celdas (píxeles), donde cada celda tiene un valor que representa una característica.

Además, muchos datos geoespaciales son también datos **espacio-temporales**, ya que poseen una componente temporal asociada a su ubicación (la fecha y hora de un accidente).

Indices Espaciales (Spatial Indexes)

Un Índice Espacial es un sistema que tesela la superficie del mundo en una rejilla de celdas regulares y de forma uniforme, asignando un identificador único a cada celda.

Este enfoque transforma costosas operaciones geométricas en operaciones de cadena de texto o numéricas, mucho más rápidas [McK22]. Las ventajas incluyen mayor eficiencia, escalabilidad, y la eliminación de sesgos inherentes a geografías administrativas irregulares.

El Índice Espacial H3: El Poder del Hexágono

Para este trabajo, se ha seleccionado H3, un sistema de indexación geoespacial jerárquico y hexagonal desarrollado por Uber [Ube18][H3 24]. El hexágono ofrece ventajas únicas para el análisis espacial, como una distancia más uniforme a sus vecinos, lo que simplifica los análisis de vecindad [McK22].

Las propiedades fundamentales de H3 son:

- **Jerarquía (Padres e Hijos):** H3 dispone de 16 niveles de resolución, permitiendo agregar y desagregar datos fácilmente entre diferentes escalas (ver Figura 2.1).

- **Anillos y Distancias (K-Rings):** Permite identificar instantáneamente los vecinos de una celda a diferentes distancias (ver Figura 2.1).



Figura 2.1: Propiedades fundamentales de H3. Izquierda: Relación jerárquica padre-hijo. Derecha: Ilustración de la función K-Ring para identificar vecinos. Adaptado de [McK22].

2.3 Métodos de Análisis Espacial

Una vez definidos los datos y las estructuras para manejarlos, el siguiente paso es aplicar algoritmos que permitan extraer patrones y conocimiento de ellos. Esta sección describe varias familias de métodos de análisis espacial, desde la partición del espacio basada en proximidad hasta la detección de agrupaciones basadas en densidad o centroides.

Análisis de Proximidad: Diagramas de Voronoi

El diagrama de Voronoi es una estructura fundamental en la geometría computacional que particiona un espacio métrico en función de la proximidad a un conjunto discreto de puntos, denominados **generadores**.

Sea $P = \{p_1, p_2, \dots, p_n\}$ un conjunto de n generadores en el plano euclideo $\mathbb{R}^2$, y sea $d(p, q)$ la distancia euclidea entre dos puntos p y q . La **región de Voronoi** (o celda) asociada a un generador $p_i \in P$, denotada como $V(p_i)$, es el lugar geométrico de todos los puntos $x \in \mathbb{R}^2$ que están más cerca de p_i que de cualquier otro generador $p_j \in P$ (con $j \neq i$). Formalmente:

$$V(p_i) = \{x \in \mathbb{R}^2 \mid d(x, p_i) \leq d(x, p_j) \text{ para todo } j \neq i\}$$

El **diagrama de Voronoi** de P , $Vor(P)$, es la colección de todas estas regiones: $Vor(P) = \{V(p_1), V(p_2), \dots, V(p_n)\}$.




Figura 2.2: Ejemplo canónico de un diagrama de Voronoi.

Construcción y Propiedades Geométricas

La construcción de cada celda $V(p_i)$ se puede entender como la intersección de $n - 1$ semiespacios cerrados. Para cada par de generadores (p_i, p_j) , la mediatriz (un hiperplano en $\mathbb{R}^n$) divide el plano en dos semiespacios. La celda $V(p_i)$ es la intersección de todos los semiespacios que contienen a p_i :

$$V(p_i) = \bigcap_{j \neq i} h(p_i, p_j) \quad \text{donde } h(p_i, p_j) = \{x \in \mathbb{R}^2 \mid d(x, p_i) \leq d(x, p_j)\}$$

De esta construcción se derivan sus propiedades clave:

1. **Teselación Convexa:** Cada celda $V(p_i)$ es un polígono convexo, y el conjunto $Vor(P)$ forma una teselación del plano $\mathbb{R}^2$.
2. **Aristas y Vértices:** Las aristas del diagrama son segmentos de las mediatrices, equidistantes a dos generadores. Los vértices son puntos equidistantes a tres o más generadores.

En la Figura 2.2 se muestra un ejemplo canónico de esta estructura. Para un tratado exhaustivo sobre los diagramas de Voronoi y sus algoritmos, véase [DBCvKO08].

Análisis de Accesibilidad: Isolíneas

El modelo de Voronoi clásico, se basa en una suposición irreal para el análisis urbano: que el desplazamiento ocurre en línea recta. Para superar esta limitación, se recurre a funciones de coste más realistas basadas en la red de transporte. Una **isolínea** es una curva que conecta puntos en los que una función dada tiene un valor constante. En nuestro contexto, las más relevantes son:

- **Isócronas:** Líneas que unen puntos a los que se puede llegar en un mismo intervalo de tiempo desde un origen. Formalmente, dado un generador p_i y un tiempo T , la isócrona es el conjunto $I_t(p_i, T) = \{x \in \mathbb{R}^2 \mid t_{net}(p_i, x) = T\}$, donde t_{net} es la función de tiempo de viaje a través de la red de carreteras.

- **Isodistancias:** Análogamente, líneas que unen puntos a una misma distancia de viaje por la red de carreteras: $I_d(p_i, D) = \{x \in \mathbb{R}^2 \mid d_{net}(p_i, x) = D\}$.

Podemos definir un **Diagrama de Voronoi Modificado** (reemplazando la métrica euclídea por una función de coste de red, como el tiempo de viaje t_{net}). La región de servicio (o área de influencia real) de un hospital p_i se define entonces como:

$$V_{net}(p_i) = \{x \in \mathbb{R}^2 \mid t_{net}(p_i, x) \leq t_{net}(p_j, x) \text{ para todo } j \neq i\}$$

Las regiones resultantes $V_{net}(p_i)$ ya no son polígonos convexos. Su forma es orgánica y depende directamente de la topología y las características de la red de carreteras. Estas estructuras, aunque conceptualmente similares a los diagramas de Voronoi, requieren algoritmos más complejos basados en análisis de redes. [OBSC00].

La diferencia entre ambos enfoques no es trivial. Como se ilustra en la Figura 2.3, la geometría de un área de servicio cambia drásticamente si se mide por tiempo o por distancia. El mapa muestra que la **isócrona de 10 minutos (azul)** tiene una forma más irregular y asimétrica, extendiéndose más por las vías rápidas, mientras que la **isodistancia de 2.5 km (marrón)** es más regular. Esta diferencia justifica la elección del tiempo como la métrica más realista para este trabajo. El proceso metodológico para generar esta comparativa se detalla en el Capítulo 3, concretamente en la Figura 3.3.




Figura 2.3: Comparativa visual de una isócrona de 10 min (azul) y una isodistancia de 2.5 km (marrón) para el Hospital La Paz.

Análisis de Clustering

El clustering o análisis de conglomerados es una tarea de aprendizaje no supervisado que busca agrupar un conjunto de objetos de tal manera que los objetos en el mismo grupo (llamado clúster) sean más similares entre sí que con los de otros grupos.

K-Means

El algoritmo K-Means es un método fundamental de clustering particional, cuyo objetivo es dividir un conjunto de N observaciones en K clústeres distintos y no solapados. Es uno de los algoritmos de aprendizaje no supervisado más populares debido a su simplicidad conceptual y eficiencia computacional para grandes conjuntos de datos [HTF09].

Formulación del Problema

Dado un conjunto de observaciones $\{x_1, x_2, \dots, x_N\}$, donde cada observación es un vector en $\mathbb{R}^p$, el objetivo de K-Means es encontrar la partición en K clústeres, $C = \{C_1, C_2, \dots, C_K\}$, que minimice la varianza intra-clúster. Esta se define comúnmente como la Suma de los Errores al Cuadrado (SSE) entre cada punto y el centroide de su clúster asignado.

Formalmente, el problema de optimización consiste en minimizar la siguiente función objetivo:

$$\min_C \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2 \quad (2.2)$$

donde μ_k es el centroide del clúster C_k , calculado como la media de todos los puntos x_i que pertenecen a ese clúster. En esencia, se busca que los puntos dentro de un mismo clúster sean lo más similares posible entre sí.

Algoritmo Iterativo

Dado que encontrar la solución óptima a la Ecuación 2.2 es un problema computacionalmente intratable (NP-hard), se utiliza un algoritmo iterativo de refinamiento, conocido como el **algoritmo de Lloyd**, que converge a un mínimo local. El algoritmo procede de la siguiente manera:

1. **Inicialización:** Se seleccionan K puntos iniciales como centroides de los clústeres. Esta selección puede ser aleatoria o mediante un método más sofisticado (k-means++).
2. **Paso de Asignación:** Cada observación es asignada al clúster cuyo centroide esté más cercano, generalmente utilizando la distancia euclídea como métrica.
3. **Paso de Actualización:** Se recalculan los centroides de cada uno de los K clústeres como la media de todas las observaciones que fueron asignadas a él en el paso anterior.
4. **Convergencia:** Los pasos 2 y 3 se repiten iterativamente hasta que las asignaciones de los clústeres ya no cambien, lo que indica que el algoritmo ha convergido.

Aplicación y Consideraciones

Si bien K-Means es un algoritmo potente, es importante destacar que asume que los clústeres son de forma esférica (convexa) y de tamaño similar. Además, su resultado puede depender de la inicialización de los centroides. En el análisis geoespacial, su resultado puede interpretarse como una **teselación de Voronoi**, donde cada celda corresponde a los puntos más cercanos a cada centroide final, lo que lo conecta con otros métodos de análisis espacial.

K-Nearest Neighbors (KNN) como Fundamento de la Vecindad Espacial

El algoritmo K-Nearest Neighbors (KNN) es un método no paramétrico y basado en instancias, utilizado fundamentalmente en tareas de aprendizaje supervisado como la clasificación y la regresión. Su mecanismo es conceptualmente sencillo pero muy potente: para predecir la etiqueta o el valor de un nuevo punto de datos, el algoritmo identifica los “k” puntos del conjunto de entrenamiento que están más cerca de él (sus “k vecinos más cercanos”) y realiza una predicción basada en ellos, por ejemplo, mediante un voto mayoritario para clasificación o una media para regresión.

Aunque en este proyecto no se utiliza KNN para fines predictivos, su principio fundamental de **definición de vecindad basada en la proximidad** es una técnica central en el análisis geoespacial. Muchos de los métodos espaciales más importantes, incluyendo los que se utilizan en este trabajo, dependen de una definición explícita de qué constituye el “entorno” de una ubicación para poder realizar comparaciones.

DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) [EKSX96], es un algoritmo de clustering basado en la noción de densidad. A diferencia de métodos particionales como K-Means, DBSCAN no requiere que se especifique el número de clústeres de antemano y posee la capacidad de identificar clústeres de formas arbitrarias y de manejar el ruido de forma nativa. Estas características lo hacen excepcionalmente adecuado para el análisis de datos geoespaciales, donde los patrones de concentración raramente siguen formas geométricas simples.

Definiciones Fundamentales

El algoritmo se fundamenta en dos parámetros clave y en la clasificación de cada punto según su vecindario local:

- **Épsilon (ϵ):** Un valor de distancia que define el radio de la vecindad alrededor de un punto.
- **Muestras Mínimas (MinPts):** El número mínimo de puntos (incluido el propio punto) que deben encontrarse dentro del radio ϵ de un punto para que este sea considerado un punto “núcleo”.

A partir de estos parámetros, los puntos del conjunto de datos se clasifican en una de tres categorías:

1. **Punto Núcleo:** Un punto que tiene al menos ‘MinPts’ vecinos dentro de su radio ϵ . Estos puntos son los “interiores” de un clúster.
2. **Punto Frontera:** Un punto que no es un punto núcleo (tiene menos de “MinPts” vecinos), pero que se encuentra en la vecindad ϵ de un punto núcleo. Estos puntos son los “frontera” de un clúster.
3. **Punto de Ruido:** Un punto que no es ni núcleo ni frontera. Estos son los puntos aislados que no pertenecen a ningún clúster denso.

Algoritmo y Formación de Clústeres

DBSCAN opera seleccionando un punto arbitrario y examinando su vecindario ϵ .

- Si el punto es un punto núcleo, se inicia un nuevo clúster. El algoritmo expande este clúster de forma recursiva, añadiendo todos los puntos núcleo y frontera que se pueden conectar a través de una cadena de puntos núcleo vecinos.
- Si el punto es un punto frontera, se pospone su asignación hasta que sea reclamado por el clúster de un punto núcleo vecino.
- Si el punto es de ruido, se descarta temporalmente. Puede ser posteriormente incluido como punto frontera de otro clúster, o permanecer como ruido si ningún clúster lo alcanza.

Este proceso se repite hasta que todos los puntos han sido visitados.

Aplicación en el Análisis de Siniestralidad

En el contexto de este trabajo, DBSCAN es la herramienta de elección para la identificación de “puntos negros” de alta siniestralidad. Al establecer un radio ϵ pequeño (15 metros) y un “MinPts” exigente (25 accidentes), el algoritmo es capaz de filtrar el “ruido” de los accidentes dispersos y aislar únicamente aquellas concentraciones que corresponden a nodos viales específicos, como intersecciones o rotondas, proporcionando un diagnóstico de alta precisión para la intervención.

2.4 Estadística Espacial para la Detección de Patrones y Relaciones

Mientras que los métodos de análisis espacial anteriores se centran en la estructura geométrica de los datos, la estadística espacial proporciona un marco formal para cuantificar la significancia de los patrones observados y modelar las relaciones entre variables en un contexto geográfico.

Autocorrelación Espacial Global: El I de Moran

Antes de buscar clústeres locales, es fundamental realizar una primera prueba para determinar si los datos presentan algún tipo de patrón espacial a nivel global. El estadístico más utilizado para esta tarea es el **I de Moran** [Mor50], que mide la autocorrelación espacial basándose tanto en las ubicaciones como en los valores de los atributos.

La fórmula del estadístico I de Moran se expresa como:

$$I = \frac{n}{S_0} \frac{\sum_{i=1}^n \sum_{j=1}^n w_{ij} z_i z_j}{\sum_{i=1}^n z_i^2} \quad (2.3)$$

donde z_i es la desviación del atributo en la ubicación i respecto a su media ($z_i = x_i - \bar{x}$), w_{ij} es el peso espacial, n es el número total de observaciones, y S_0 es la suma de todos los pesos espaciales.

El valor de I varía entre -1 (dispersión perfecta) y +1 (agrupamiento perfecto), mientras que un valor cercano a 0 sugiere una distribución espacial aleatoria. Para el conjunto de datos de este trabajo, la herramienta de análisis espacial de CARTO calculó un **I de Moran global de 0.53**. Este valor, al ser fuertemente positivo, proporciona un **indicio claro de la existencia de una autocorrelación espacial positiva** en la siniestralidad de Madrid. Dado que el I de Moran global solo indica la presencia de un patrón pero no su ubicación ni su significancia estadística formal, el siguiente paso lógico es utilizar indicadores locales.

Detección de Patrones Locales: Indicadores Locales de Asociación Espacial (LISA)

El I de Moran global nos dice *si* existe un patrón, pero no *dónde*. Para localizar los patrones, se emplean los **Indicadores Locales de Asociación Espacial (LISA)**, concepto introducido por Anselin [Ans95].

Un método LISA descompone el indicador global de autocorrelación en la contribución específica de cada unidad espacial. Esto permite la identificación de dos tipos principales de patrones:

- **Clústeres espaciales:** Agrupaciones de valores similares, como puntos calientes (alta concentración de valores altos) o puntos fríos (alta concentración de valores bajos).
- **Atípicos (Outliers) espaciales:** Ubicaciones individuales cuyos valores son marcadamente diferentes a los de su entorno (un valor alto rodeado de valores bajos).

*El Estadístico Getis-Ord G_i^**

Desarrollado por Getis y Ord [GO92, OG95], este estadístico está diseñado específicamente para responder a la pregunta: ¿la concentración local de valores alrededor de una ubicación i es significativamente mayor o menor de lo esperado? Es la herramienta ideal para el **análisis de puntos calientes (hotspots) y fríos (coldspots)**. La versión

estandarizada del estadístico es:

$$G_i^* = \frac{\sum_{j=1}^n w_{ij}x_j - \bar{X} \sum_{j=1}^n w_{ij}}{S \sqrt{\frac{n \sum_{j=1}^n w_{ij}^2 - (\sum_{j=1}^n w_{ij})^2}{n-1}}} \quad (2.4)$$

Interpretación

Donde x_j es el valor del atributo, w_{ij} es el peso espacial, n es el número total de unidades, $\bar{X}$ es la media y S es la desviación estándar. El valor G_i^* resultante es un puntaje Z (Z-score). Un valor alto y positivo indica un **hotspot**, mientras que un valor bajo y negativo indica un **coldspot**. Para que este patrón sea considerado robusto, debe ser estadísticamente significativo (p-value <0.05).

El Estadístico I de Moran Local

El Local Moran's I [Ans95] responde a una pregunta más matizada: ¿la relación entre el valor de una ubicación i y los valores de sus vecinos es de similitud o de disparidad? Su principal ventaja es su capacidad para detectar no solo clústeres de valores similares, sino también **atípicos (outliers) espaciales**. Su formulación computacional, presentada en obras de referencia como [BPGR13], es:

$$I_i = \frac{x_i - \bar{X}}{S^2} \sum_{j=1, j \neq i}^n w_{ij}(x_j - \bar{X}) \quad (2.5)$$

Interpretación

- $(x_i - \bar{X})$: La desviación del valor de la ubicación i respecto a la media global.
- $\sum w_{ij}(x_j - \bar{X})$: La suma ponderada de las desviaciones de los vecinos de i respecto a la media global. Este término se conoce como la **variable espacialmente retardada** (spatially lagged variable) y representa el valor promedio del entorno de i .
- S^2 : La varianza de la muestra, utilizada para estandarizar el resultado.

La interpretación del signo y magnitud de I_i da lugar a cuatro categorías: **High-High** (clúster caliente), **Low-Low** (clúster frío), **High-Low** (outlier, isla de peligro) y **Low-High** (outlier, isla de seguridad). Al igual que con el G_i^* , la asignación a una de estas categorías solo es relevante si el patrón es estadísticamente significativo.

Análisis de Hotspots en el Espacio-Tiempo

La evolución natural de estas técnicas es la incorporación de la dimensión temporal para detectar patrones que cambian en el tiempo. El concepto fundamental es el **cubo espacio-tiempo**, una estructura de datos tridimensional donde las dimensiones X e Y representan el espacio, y la tercera dimensión representa el tiempo (Figura 2.5). Esto permite clasificar hotspots en categorías dinámicas como **emergentes**, **persistentes** o **esporádicos** [McK23].




Figura 2.4: Diferencia conceptual entre Getis-Ord G_i^* y el I de Moran Local.




Figura 2.5: Representación conceptual de un cubo espacio-temporal.

Análisis de Relaciones: Regresión Geográficamente Ponderada (GWR)

Mientras que los métodos LISA identifican *patrones* de concentración, la Regresión Geográficamente Ponderada (GWR) es una técnica exploratoria que investiga las *relaciones* entre variables. Su propósito es abordar la **no estacionariedad espacial**: la idea de que estas relaciones pueden cambiar a lo largo del espacio.

GWR es un modelo de regresión local que estima un conjunto de parámetros para cada ubicación. El modelo se expresa como:

$$y_i = \beta_0(u_i, v_i) + \sum_{k=1}^p \beta_k(u_i, v_i) x_{ik} + \varepsilon_i \quad (2.6)$$

El resultado principal de GWR es un conjunto de **superficies de parámetros** que se pueden mapear para visualizar cómo la influencia de cada variable explicativa cambia geográficamente [FBC02].

Metodología y Diseño Experimental

Este capítulo detalla el proceso técnico y metodológico seguido para transformar los datos brutos de siniestralidad en un análisis comprensivo y visual. Se describe el flujo de trabajo completo, estructurado en cuatro fases principales que abarcan desde la adquisición y el preprocesamiento de los datos, hasta su análisis y visualización mediante plataformas especializadas.

3.1 Visión General del Flujo de Trabajo y Herramientas

El análisis se estructuró en cuatro fases secuenciales, combinando herramientas locales y plataformas en la nube para cubrir todo el ciclo de vida del dato, desde su adquisición hasta su análisis avanzado.

1. **Fase 1: Preprocesamiento y Limpieza de Datos (R).** Consolidación, limpieza y enriquecimiento de las diversas fuentes de datos para generar un conjunto de datos limpio.
2. **Fase 2: Análisis Exploratorio y Visualización Interactiva (Tableau).** Creación de dashboards interactivos para la exploración de patrones temporales, perfiles demográficos y relaciones entre variables a nivel general.
3. **Fase 3: Modelado y Análisis Espacial Avanzado (CARTO Workflows).** Aplicación de técnicas geoespaciales para el enriquecimiento de datos, la creación de áreas de servicio y el desarrollo de un perfil de riesgo de alta resolución.
4. **Fase 4: Diseño de Mapas Analíticos (CARTO Builder).** Traducción de los resultados del modelado espacial a mapas temáticos e interactivos para la comunicación visual de los hallazgos geográficos.

Las herramientas software utilizadas en este proyecto han sido:

- **RStudio** versión 2024.04[R C23]
- **Tableau Desktop (public edition)** versión 2025.02
- **CARTO (“CARTO for Education” de GitHub Student)** versión Q2 2025
- **Overleaf** versión 2023-11-01

3.2 Fuentes de Datos y Adquisición

El análisis se fundamenta en la integración de múltiples fuentes de datos, cuya descripción y estructura detallada se encuentra en el Apéndice B. A continuación, se resumen las fuentes principales:

- **Datos de Accidentalidad:** El conjunto de datos principal fue obtenido del Portal de Datos Abiertos del Ayuntamiento de Madrid [Ayu25]. Contiene un registro por cada persona implicada en un accidente entre 2019 y 1er. cuatrimestre 2025, con variables clave como número de expediente, fecha, hora, coordenadas UTM, tipo de accidente, lesividad, y características de los implicados.
- **Límites de Distritos de Madrid:** Archivo GeoJSON que define los polígonos de los distritos administrativos, esencial para la agregación y contextualización espacial de los accidentes.
- **Ubicación de Radares y Cámaras:** Se recopilaron datos sobre la localización de radares fijos, cámaras Circuito Cerrado de Television (CCTV) y cámaras de Zonas de Bajas Emisiones (ZBE/ZBEDEP) del Ayuntamiento de Madrid, en formatos como KML y CSV.
- **Ubicación de Hospitales:** Coordenadas de los principales centros hospitalarios de Madrid, utilizadas para los análisis de accesibilidad y áreas de servicio.

Para una consulta exhaustiva de la estructura de columnas y valores de cada fichero, véase el Apéndice B.

3.3 Fase 1: Preprocesamiento de Datos con R

El preprocesamiento se realizó en R mediante el script `clean_to_CARTO.R`, cuyo código completo se detalla en el Apéndice (Sección A.1). El objetivo de esta fase fue unificar las diversas fuentes de datos en un conjunto de archivos GeoJSON limpios, coherentes y listos para el análisis.

El proceso se puede resumir en los siguientes pasos clave:

1. **Carga y Limpieza Iterativa:** Se implementó un bucle para leer los archivos CSV anuales de accidentalidad. En este paso se estandarizaron múltiples cadenas de texto (e.g., “Se desconoce”, “NULL”) como valores ausentes (NA) y se filtraron registros que carecían de coordenadas geográficas válidas.
2. **Enriquecimiento de Variables Temporales:** Las columnas de fecha y hora se procesaron para generar nuevas variables categóricas y ordenadas, como el año, mes, día de la semana y rangos horarios (mañana, tarde, noche), lo cual es fundamental para facilitar los análisis de tendencias.
3. **Recategorización de Variables Clave:** Se crearon nuevas columnas de clasificación para agrupar categorías complejas y mejorar la interpretabilidad. Las variables `lesividad`, `tipo_accidente` y `tipo_vehiculo` fueron consolidadas en categorías más generales (e.g., “HERIDOS GRAVES”, “Colisión doble”, “Turismo/Furgoneta”), permitiendo un análisis más agregado y claro.
4. **Geoprocésamiento y Transformación de Coordenadas:** Los datos tabulares se convirtieron en objetos espaciales de la clase `sf`. Se asignó su sistema de coordenadas original (UTM Zona 30N, EPSG:25830) para luego transformarlos al estándar global WGS 84 (EPSG:4326), garantizando así la compatibilidad con las plataformas de mapeo web como CARTO.

5. **Consolidación de Fuentes Auxiliares:** De manera análoga, se procesaron las fuentes de datos adicionales (distritos, radares, cámaras, hospitales), unificando sus formatos y sistemas de coordenadas para asegurar su correcta integración en los análisis posteriores.
6. **Exportación:** Finalmente, todos los objetos espaciales procesados se exportaron a formato GeoJSON, el estándar de facto para datos geoespaciales en la web.

3.4 Fase 2: Visualización Analítica con Tableau

Para la exploración de los datos y la comunicación de patrones generales, se utilizó Tableau Desktop. La metodología de desarrollo se centró en la creación de un sistema de visualización interactivo y narrativo, desde la preparación de los datos hasta la presentación final de los resultados.

Diseño y Creación de Dashboards

El proceso en Tableau se estructuró de la siguiente manera:

1. **Conexión y Verificación de Datos:** Se estableció una conexión directa al fichero de datos procesado, verificando la correcta interpretación de los tipos de campo por parte de la herramienta para garantizar la integridad del análisis.
2. **Creación de Campos Calculados:** Se generaron métricas y dimensiones personalizadas. Un aspecto metodológico clave fue el uso de **Expresiones de Nivel de Detalle (LODs)**, como `{FIXED [num_expediente] : ...}`, para realizar cálculos a nivel de accidente único (determinar la máxima lesividad de un siniestro) y propagar ese valor a todas las filas de implicados correspondientes a dicho suceso. La lista completa de estos campos, junto con su lógica, se encuentra en el Apéndice (Sección A.3).
3. **Desarrollo de Hojas de Trabajo y Dashboards Temáticos:** Se diseñaron hojas de trabajo individuales para responder a preguntas de investigación específicas, empleando una variedad de gráficos (barras, líneas, circulares...). Estas hojas se ensamblaron en siete dashboards temáticos, cada uno con un enfoque analítico claro, buscando un equilibrio entre la densidad de información y la legibilidad.
4. **Ensamblaje del Story Interactivo:** Finalmente, los dashboards se integraron en un *Story* de Tableau, presentando los hallazgos de forma secuencial y guiada. El Story completo fue publicado en Tableau Public para su consulta abierta.

El Story completo, con todos los dashboards interactivos, ha sido publicado en la plataforma Tableau Public para su consulta abierta.

[Acceder al Story Interactivo en Tableau Public](#)

3.5 Fase 3: Modelado y Análisis Espacial con CARTO Workflows

Para profundizar en la dimensión geográfica, se empleó la herramienta *Workflows* de CARTO para ejecutar análisis espaciales avanzados. Se diseñaron seis flujos de trabajo principales.

Workflow 1: Enriquecimiento de Datos y Muestreo

El primer workflow implementado en CARTO, cuyo diagrama se presenta en la Figura 3.1, tiene como objetivo principal el preprocesamiento y la estructuración final de los datos de accidentalidad para los análisis subsecuentes. Este proceso aborda dos tareas fundamentales: el enriquecimiento geográfico de los datos y la generación de conjuntos de datos con diferentes niveles de granularidad.




Figura 3.1: Diagrama del workflow de CARTO para el enriquecimiento y muestreo de los datos de accidentalidad.

Las fuentes de datos de entrada para este flujo de trabajo son:

- **accidentalidad_sin_distrito**: La tabla principal, resultado de la Fase 1, que contiene un registro por cada persona implicada en un accidente.
- **distritos**: La tabla con los polígonos geográficos de los distritos de Madrid, utilizada como capa de enriquecimiento.

El workflow se desarrolla en los siguientes pasos lógicos:

Paso 1: Enriquecimiento Geográfico por Distrito

El primer paso consiste en asignar a cada accidente el distrito en el que ocurrió. Para ello, se ejecuta una **unión espacial** (*spatial join*) utilizando la función geoespacial ST_INTERSECTS. Esta operación compara la ubicación puntual de cada accidente de la tabla `accidentalidad_sin_distrito` con los polígonos de la tabla `distritos`. Cuando un punto de accidente se encuentra dentro de un polígono de distrito, la información de dicho distrito (principalmente su nombre) se añade al registro del accidente. El resultado es una tabla enriquecida, guardada como `accidentalidad`, que contiene todos los datos originales más la columna `distrito`.

Paso 2: Creación de una Tabla de Accidentes Únicos

La tabla enriquecida mantiene una granularidad a nivel de “persona implicada”, lo que significa que un mismo accidente aparece en múltiples filas si hubo varios implicados. Para análisis donde la unidad de observación es el evento en sí (e.g., contar el número de accidentes por día), es necesario cambiar esta granularidad.

Este paso transforma los datos de la siguiente manera:

1. Se eliminan temporalmente las columnas específicas de cada persona (como `tipo_persona`, `lesividad`, `rango_edad`, etc.).
2. Se aplica una operación para eliminar filas duplicadas (`Remove Duplicates`), basándose en el identificador único del accidente, `num_expediente`.

El resultado de este proceso es la tabla `accidentes`, donde cada fila representa un único evento de accidente, con su ubicación y fecha correspondientes.

Paso 3: Generación de una Muestra para Análisis Detallado

Para ciertos análisis o para la creación de prototipos visuales, trabajar con el conjunto de datos completo (cientos de miles de registros) puede ser computacionalmente intensivo. Por ello, se genera una muestra más manejable.

1. Se aplica un muestreo aleatorio (`Sample`) sobre la tabla de accidentes únicos para seleccionar 1000 expedientes al azar.
2. Esta lista de 1000 expedientes se utiliza como filtro en una operación de unión (`Join`) con la tabla original enriquecida (la que tiene granularidad por persona).

El resultado final de este paso es la tabla `accidentalidad_sample`, que contiene todos los registros detallados (incluyendo todas las personas implicadas) correspondientes únicamente a los 1000 accidentes seleccionados.

Salidas Generadas y Notificación

Este workflow produce tres tablas finales para su uso en análisis posteriores: `accidentalidad` (datos completos enriquecidos), `accidentes` (una fila por accidente único) y `accidentalidad_sample` (muestra detallada). Adicionalmente, el workflow está configurado para exportar la tabla completa a un fichero CSV y enviar una notificación por correo electrónico con el enlace de descarga, una funcionalidad útil para la integración con otras herramientas o para compartir resultados.

Workflow 2: Análisis de Áreas de Influencia con Diagramas de Voronoi

Para realizar una primera aproximación a las áreas de servicio o zonas de captación de los hospitales, se implementó un workflow (Figura 3.2) que calcula el diagrama de Voronoi. Como se describió en la Sección 2.3, este método particiona el espacio en regiones donde cada punto es asignado al “semillero” más cercano, en este caso, los hospitales. El objetivo es determinar, bajo la suposición de distancia euclídea, qué área geográfica está más próxima a cada centro hospitalario.




Figura 3.2: Diagrama del workflow de CARTO para el análisis de áreas de servicio con Diagramas de Voronoi.

Las fuentes de datos de entrada para este flujo de trabajo son:

- **hospitales**: La tabla con las ubicaciones puntuales de los centros hospitalarios.
- **distritos**: La tabla con los polígonos de los distritos, utilizada para definir el área de estudio.

El workflow se desarrolla en los siguientes pasos lógicos:

Paso 1: Creación del Límite Geográfico de Madrid

Primero se define el contorno del área de análisis con una operación de agregación espacial sobre la tabla `distritos`. La función `ST_UNION(ARRAY_AGG(geom))` fusiona todos los polígonos de los distritos individuales en una única geometría compleja que

representa la frontera municipal de Madrid. Esta geometría se almacena en la tabla `distritos_union` y será utilizada posteriormente para recortar el diagrama de Voronoi.

Paso 2: Generación y Ajuste de los Polígonos de Voronoi

Este es el núcleo del análisis y se realiza en varios sub-pasos encadenados:

1. **Cálculo de la Teselación:** Se utiliza una consulta SQL personalizada para invocar la función `ST_VORONOI_POLYGONS`. Esta función toma como entrada los puntos de los hospitales y genera la teselación de Voronoi. Para asegurar una cobertura completa, la función calcula los polígonos dentro de la caja delimitadora (*bounding box*) del contorno de Madrid.
2. **Recorte de las Celdas:** Las celdas de Voronoi generadas inicialmente exceden los límites reales de la ciudad. Para ajustarlas, se realiza una **intersección espacial** (`ST_Intersection`) entre cada celda de Voronoi y el polígono del límite de Madrid (`distritos_union`) creado en el paso anterior. Esta operación recorta cada celda para que su forma se ajuste perfectamente al contorno municipal.
3. **Limpieza de Columnas:** Finalmente, se eliminan las columnas geométricas intermedias que ya no son necesarias y se renombra la columna con la geometría final y recortada a `voronoi_distritos_cell` para mayor claridad.

Salidas Generadas

Este workflow produce dos tablas finales que son esenciales para la visualización y el análisis posterior:

- **`distritos_union`:** Contiene la geometría única del contorno de Madrid.
- **`voronoi`:** La tabla principal de resultados. Cada fila contiene una celda de Voronoi ajustada (un polígono) y la información del hospital al que está asociada, representando su área de influencia teórica.

Workflow 3: Comparación de Isócronas e Isodistancias

Como se ha ilustrado en el marco teórico (ver Figura 2.3), la elección entre tiempo y distancia como métrica de accesibilidad tiene un impacto visual y analítico significativo. Para llevar a cabo esta comparación de forma rigurosa, se diseñó y ejecutó un workflow específico, cuyo diagrama de flujo se presenta en la Figura 3.3.

Este proceso metodológico, aunque sencillo, es fundamental para validar la decisión de utilizar isócronas en el análisis principal. El workflow toma como origen un único hospital (el Hospital La Paz) y calcula simultáneamente dos polígonos de área de servicio: uno basado en un tiempo de viaje de 10 minutos y otro en una distancia de 2.5 km. El resultado es una tabla que permite la superposición y comparación directa de ambas geometrías. El script SQL completo que implementa esta lógica se puede consultar en el Apéndice A, concretamente en el listado A.4.




Figura 3.3: Diagrama del workflow utilizado para la comparación metodológica de isócronas.

Workflow 4: Desarrollo del Perfil de Riesgo Hospitalario

Este workflow representa el análisis espacial más avanzado del trabajo. Su objetivo es superar las limitaciones de los análisis agregados por distrito o de los diagramas de Voronoi, generando un **mapa de riesgo de alta resolución** para toda la ciudad de Madrid. Para ello, en lugar de promediar el riesgo por zonas administrativas, se calcula un perfil de riesgo para cada celda de un grid hexagonal, permitiendo la detección de micro-clústeres con una mayor precisión. El diagrama completo del proceso se muestra en la Figura 3.4.

El análisis se centra en cuantificar tres métricas de riesgo para cada hexágono:

1. **Volumen Total:** Número de accidentes únicos.
2. **Alta Severidad:** Número de accidentes con heridos graves o fallecidos.
3. **Riesgo Peatonal:** Número de atropellos.

El workflow se desarrolla en cuatro fases metodológicas:

Paso 1: Generación de Zonas de Servicio (Isócronas H3)

El primer paso consiste en definir las áreas de servicio realistas basadas en tiempo de viaje y estandarizarlas en una parrilla H3.

- **Cálculo de Isócronas:** Se utiliza el nodo `Create Isolines` para generar polígonos de tiempo de viaje (isócronas) de 5, 10 y 15 minutos en coche desde la ubicación de cada hospital.
- **Conversión a H3:** Cada polígono de isócrona se convierte a un conjunto de celdas hexagonales del sistema H3 (resolución 9) mediante el nodo `H3 Polyfill`. La unión de todas estas celdas H3 resultantes actúa como el “mapa de referencia” o área de estudio para el análisis posterior.

3.5. Fase 3: Modelado y Análisis Espacial con CARTO Workflows




Figura 3.4: Diagrama del workflow de CARTO para la creación del perfil de riesgo basado en isócronas y H3.

Paso 2: Preparación de los Datos de Accidentes

Paralelamente, se preparan los datos de accidentalidad para poder agregarlos al grid hexagonal. Se generan dos conjuntos de datos clave:

- **Todos los Accidentes:** La tabla `accidentes` (con un registro por accidente único) se procesa con el nodo `H3 from GeoPoint`. Esta operación asigna a cada accidente el identificador de la celda H3 en la que se encuentra.
- **Accidentes Graves:** Se utiliza una consulta SQL personalizada para filtrar la tabla `accidentalidad` y seleccionar únicamente los siniestros con implicados cuya `lesividad_clasificada` sea `'HERIDOS GRAVES'` o `'FALLECIDOS'`. Este subconjunto de alta severidad se guarda en la tabla `accidentes_graves` y, al igual que el conjunto completo, se indexa con H3.

Paso 3: Cálculo de Métricas de Riesgo por Hexágono

Este es el corazón del análisis, donde se cuantifica el riesgo para cada hexágono individual. Una única y potente consulta SQL personalizada (`Custom SQL`) realiza las siguientes operaciones:

1. **Unión de Datos:** Se une la tabla de referencia de celdas H3 (generada en el Paso 1) con los dos conjuntos de datos de accidentes indexados (del Paso 2) utilizando el identificador H3 como clave.
2. **Agregación por Hexágono:** Se agrupan los datos por cada celda H3 individual (GROUP BY a.h3).
3. **Cálculo de Métricas:** Para cada grupo (cada hexágono), se calculan las tres métricas de riesgo: el conteo de accidentes totales, el conteo de accidentes graves y el conteo de atropellos.

El resultado es una tabla donde cada fila representa un hexágono único, enriquecido con sus propias métricas de riesgo calculadas.

Paso 4: Ensamblaje Final, Geometría y Recorte

El último paso consiste en preparar los datos para su visualización en un mapa.

- **Creación de Geometría:** El nodo H3 Boundary se utiliza para transformar los identificadores H3 de la tabla de resultados en geometrías de polígonos hexagonales visibles.
- **Recorte al Límite Municipal:** Para asegurar una visualización limpia y precisa, se realiza una intersección espacial (ST_INTERSECTION) para recortar los hexágonos con el polígono de distritos_union, eliminando cualquier parte de los hexágonos que quede fuera del contorno de Madrid.
- **Almacenamiento Final:** El resultado se guarda en una tabla final, lista para ser visualizada en CARTO Builder.

Workflow 5: Detección de Clústeres Espaciales (LISA)

Finalmente, se diseñó un workflow para aplicar los Indicadores Locales de Asociación Espacial (LISA) descritos en el marco teórico (Figura 3.5). El objetivo era identificar clústeres estadísticamente significativos de alta y baja accidentalidad (puntos calientes y fríos) utilizando los estadísticos Getis-Ord Gi* y Local Moran's I. El script SQL completo generado por este workflow se puede consultar en el Apéndice, Sección A.2.

El proceso consiste en tomar los accidentes únicos, agruparlos espacialmente en una parrilla H3 para obtener el volumen de accidentes por celda, y posteriormente aplicar ambos estadísticos sobre esta variable. Para ambos cálculos, se definió una vecindad de tamaño 1 (considerando solo los hexágonos inmediatamente adyacentes) y se utilizó una función de ponderación espacial uniforme.

Desafíos Metodológicos y Adaptación del Modelo

Durante la implementación de este workflow, se encontraron limitaciones computacionales que requirieron una adaptación del enfoque inicial.




Figura 3.5: Workflow de CARTO para el análisis de autocorrelación espacial (LISA) a resolución H9.

- **Intento Inicial (Resolución H10):** Se realizó un primer intento utilizando una parrilla H10 para obtener la máxima precisión espacial. Sin embargo, el gran número de hexágonos resultante provocó que el cálculo de las permutaciones para el Local Moran's I, un proceso computacionalmente intensivo, excediera los límites de recursos de la plataforma. Esto obligó a reducir el número de permutaciones a un valor testimonial ($n=3$), insuficiente para obtener significancia estadística (el p-value mínimo posible era de 0.25). La visualización de este intento fallido se incluye en el Apéndice C.
- **Adaptación del Enfoque (Resolución H9):** Para superar esta limitación, se tomó la decisión metodológica de reducir la resolución del análisis a H9. Este enfoque, aunque ligeramente menos granular, reduce drásticamente el número de unidades espaciales a procesar, permitiendo ejecutar el análisis con un número de permutaciones estadísticamente robusto ($n=99$).

Este proceso iterativo subraya el compromiso necesario entre la granularidad del análisis y la viabilidad computacional. Por tanto, los resultados que se presentan en el Capítulo 4 corresponden al análisis realizado a resolución H9.

Workflow 6: Identificación de Puntos Negros con DBSCAN

Para complementar los análisis basados en rejillas y realizar un diagnóstico de alta precisión, se diseñó un workflow final para identificar “puntos negros” mediante el algoritmo DBSCAN. El objetivo era localizar las concentraciones de accidentes más extremas y caracterizar su perfil de siniestralidad.

La metodología, como se muestra en la Figura 3.6, se desarrolló en dos etapas. Primero, se aplicó el nodo ST Cluster DBSCAN sobre los puntos de accidentes únicos con parámetros de alta exigencia: un radio de búsqueda (*epsilon*) de **15 metros** y un mínimo de **25 accidentes** (*min_samples*) para constituir un clúster. Segundo, mediante una

consulta SQL personalizada (ver Apéndice, Sección A.2), los puntos de cada clúster se agruparon para generar un polígono de su envolvente convexa y, simultáneamente, enriquecerlo con métricas agregadas como el número total de accidentes y el desglose por tipo.



Figura 3.6: Workflow de CARTO para la identificación y caracterización de puntos negros con DBSCAN.

3.6 Fase 4: Diseño de Mapas Analíticos con CARTO Builder

Las tablas de datos generadas por los workflows son el insumo para la creación de los mapas analíticos finales, tarea realizada en la interfaz de **CARTO Builder**. El proceso metodológico para la construcción de cada mapa fue el siguiente:

- Carga de la Fuente de Datos:** Se añadió la tabla de resultados del workflow (e.g., `perfil_riesgo_hospitales_madrid_por_hexagono`) como una nueva capa en el mapa.
- Estilo de la Capa (Styling):** Se aplicó un estilo coroplético a los polígonos de la capa. Estos fueron coloreados según el valor de una de las métricas de análisis (e.g., `volumen_total_accidentes`), utilizando una rampa de color secuencial para representar visualmente la intensidad del fenómeno.
- Configuración de la Interacción:** Se definieron ventanas emergentes (pop-ups) y etiquetas flotantes (tooltips) para que, al interactuar con un polígono, se muestre la información detallada de sus atributos (nombre del hospital, métricas de riesgo, etc.).
- Diseño Final del Mapa:** Se seleccionaron mapas base (como el de Positron o Dark Matter) para no restar protagonismo a los datos y se configuró una leyenda clara y autoexplicativa para facilitar la interpretación de los resultados.

Resultados y Análisis

Este capítulo presenta los principales hallazgos del análisis de la accidentalidad en Madrid. Se estructura en dos grandes bloques. En primer lugar, se exponen los resultados del análisis exploratorio realizado con Tableau, que permiten identificar patrones temporales, perfiles de implicados y factores de riesgo a nivel general. En segundo lugar, se presentan los resultados del modelado espacial avanzado ejecutado en CARTO, revelando la dimensión geográfica de la siniestralidad a través de mapas de áreas de influencia y perfiles de riesgo.

4.1 Análisis Exploratorio de Patrones con Tableau

A continuación, se presenta el análisis detallado de cada uno de los siete dashboards desarrollados en Tableau, que en conjunto ofrecen una visión multifacética de la siniestralidad.

Dashboard 1: Panel de Control y Proyección de Accidentalidad

Este dashboard ofrece una visión general de la magnitud de la siniestralidad y una proyección a futuro.



Figura 4.1: Panel de Control y Proyección de Accidentalidad.

Preguntas Clave Respondidas: ¿Cuál es la magnitud global de la accidentalidad? ¿Cuál es la tendencia histórica y la proyección futura de los accidentes?

Hallazgos y Conclusiones Directas:

- Durante el periodo analizado, se registraron 122 473 que involucraron a 287 435 personas. De los conductores implicados, 8893 dieron positivo en pruebas de alcohol o drogas, y se contabilizaron 178 fallecidos.

4. RESULTADOS Y ANÁLISIS

- La serie histórica de accidentes muestra una notable disminución en 2020, coincidiendo con las restricciones por la pandemia de COVID-19. Posteriormente, se observa una recuperación y estabilización. El modelo de pronóstico de Tableau sugiere una continuación de esta tendencia estable, con las fluctuaciones estacionales características.
- **Conclusión Principal:** La accidentalidad en Madrid representa un problema de considerable magnitud. La persistencia de un elevado número de siniestros, junto con la incidencia de factores de riesgo, subraya la necesidad de mantener y reforzar las estrategias de seguridad vial.

Dashboard 2: Accidentes: Distribución Geográfica y Anual

Este dashboard explora la concentración espacial de los accidentes por distritos y su evolución temporal.




Figura 4.2: Accidentes: Distribución Geográfica y Anual.

Preguntas Clave Respondidas: ¿En qué distritos se concentra la mayor cantidad de accidentes? ¿Cómo ha sido la evolución anual y trimestral?

Hallazgos y Conclusiones Directas:

- Los distritos de **Puente de Vallecas, Carabanchel y Salamanca** son los que registran una mayor concentración de accidentes, evidenciando una heterogeneidad significativa en la distribución geográfica de la siniestralidad.
- Tras el pico de 2019 (21 906 accidentes) y la caída en 2020, el número de siniestros se ha estabilizado en cifras superiores a 20 000 anuales. El análisis trimestral muestra variaciones estacionales.
- **Conclusión Principal:** La identificación de distritos con alta siniestralidad es fundamental para la asignación eficiente de recursos y la planificación de intervenciones preventivas localizadas.

Dashboard 3: Accidentes: Patrones Diarios, Horarios y Tipología

Análisis de los momentos y tipos de accidentes más frecuentes.




Figura 4.3: Accidentes: Patrones Diarios, Horarios y Tipología.

Preguntas Clave Respondidas: ¿En qué días y horas ocurren más accidentes? ¿Cuáles son los tipos de colisión más comunes?

Hallazgos y Conclusiones Directas:

- Los **viernes** y las franjas horarias de la **mañana (8-9h y 14h)** y la **tarde (13-20h)** concentran el mayor número de siniestros, coincidiendo con los picos de movilidad laboral.
- La **colisión doble** (48 706) y el **alcance** (25 789) son las tipologías más frecuentes.
- **Conclusión Principal:** Los patrones temporales están estrechamente ligados a la movilidad urbana, y las tipologías más comunes sugieren áreas de enfoque para mejorar la seguridad en interacciones vehiculares.

Dashboard 4: Implicados: Visión General, Lesividad y Rol

Este dashboard se centra en las personas involucradas en los accidentes.

Preguntas Clave Respondidas: ¿Cuál es la distribución de la gravedad de las lesiones? ¿Cómo influye el rol (conductor, pasajero, peatón) en la lesividad?

Hallazgos y Conclusiones Directas:

- La mayoría de los implicados resultan ilesos (88 149) o con heridas leves (66 067). Los conductores representan el 80.62 % de los implicados.
- Un análisis crítico revela que los **peatones están sobrerrepresentados en las categorías de mayor gravedad**, conformando el 43.26% de los fallecidos y el 31.07 % de los heridos graves.

4. RESULTADOS Y ANÁLISIS




Figura 4.4: Implicados: Visión General, Lesividad y Rol.

- **Conclusión Principal:** La vulnerabilidad de los peatones es un aspecto crítico, ya que enfrentan un riesgo desproporcionadamente alto de sufrir lesiones graves o fatales.

Dashboard 5: Análisis Detallado de Severidad

Exploración de factores que modulan la gravedad de los accidentes.




Figura 4.5: Análisis Detallado de Severidad: Factores y Grupos.

Preguntas Clave Respondidas: ¿Cómo se correlacionan la edad, el tipo de vehículo y el clima con la severidad de las consecuencias?

Hallazgos y Conclusiones Directas:

- La severidad de las lesiones aumenta significativamente en los rangos de edad más avanzados, especialmente en el grupo de **más de 74 años**.
- Los usuarios de **motocicleta y patinete** presentan una proporción mayor de consecuencias graves en comparación con los ocupantes de turismos.
- Aunque los accidentes con tiempo despejado son más numerosos, condiciones como la **lluvia intensa** parecen asociarse con una proporción relativamente mayor de accidentes fatales.
- **Conclusión Principal:** La severidad de los accidentes se ve modulada por la vulnerabilidad del implicado (edad, tipo de vehículo) y, en menor medida, por las condiciones climáticas.

Dashboard 6: Perfil del Conductor Implicado

Características demográficas de los conductores.




Figura 4.6: Perfil del Conductor Implicado.

Preguntas Clave Respondidas: ¿Cuáles son las características demográficas de los 231 723 conductores implicados?

Hallazgos y Conclusiones Directas:

- El perfil del conductor implicado es predominantemente **masculino (74.55%)**, de **edad media (25-54 años)** y usualmente al volante de un turismo o furgoneta.
- **Conclusión Principal:** Este perfil demográfico puede guiar el diseño de campañas de concienciación y prevención específicas.

Dashboard 7: Conductores: Consumo de Sustancias y Fatalidades

Análisis del impacto del consumo de alcohol y drogas.



Figura 4.7: Conductores: Consumo de Sustancias y Consecuencias Fatales.

Preguntas Clave Respondidas: ¿Cuál es la prevalencia y perfil del consumo de sustancias entre los conductores implicados?

Hallazgos y Conclusiones Directas:

- El consumo de sustancias, especialmente **alcohol**, es un factor de riesgo crítico.
- Los conductores positivos se concentran en los segmentos de edad más **jóvenes** (21-29 años).
- Existe una clara vinculación entre el consumo de sustancias por parte de los conductores y las **consecuencias fatales** (20 fallecidos en estos siniestros).
- **Conclusión Principal:** La lucha contra la conducción bajo los efectos del alcohol y las drogas, con especial foco en los jóvenes, es una prioridad para reducir la mortalidad en carretera.

4.2 Resultados del Modelado Espacial con CARTO

Complementando el análisis exploratorio, se utilizó CARTO para investigar la dimensión geográfica de la siniestralidad. A continuación se presentan los mapas resultantes de los workflows de análisis.

Panorámica de la Concentración: Análisis de Clústeres

Como primera aproximación visual a la dimensión geográfica del problema, se generó un mapa de clústeres para responder a la pregunta fundamental: ¿dónde se concentran los accidentes en Madrid? En lugar de mostrar miles de puntos individuales que saturarían la vista, se utilizó una técnica de agregación que agrupa automáticamente los puntos cercanos.

Como se observa en la Figura 4.8, cada círculo representa un grupo de accidentes, y su tamaño y el número en su interior indican la cantidad de siniestros que contiene.




Figura 4.8: Mapa de clústeres que muestra la concentración de accidentes en Madrid. [Explorar el mapa interactivo en CARTO.](#)

Análisis e Interpretación: La observación de este mapa permite extraer una conclusión principal de forma inmediata y contundente:

- **La accidentalidad está extremadamente concentrada.** El riesgo no se distribuye de manera uniforme por el municipio. Existe una concentración masiva de siniestros en el núcleo central de la ciudad, como demuestran los clústeres con valores de 17.6k, 15.4k y 12.9k.
- **Se evidencia un drástico contraste centro-periferia.** Mientras el corazón de la ciudad acumula decenas de miles de incidentes, las áreas más alejadas registran cifras significativamente menores.

En resumen, este mapa introductorio establece que el problema de la siniestralidad vial en Madrid es, en gran medida, un fenómeno del entorno urbano denso. Esto jus-

tifica la necesidad de los análisis más profundos que se presentan a continuación para entender las características específicas del riesgo en estas áreas críticas.

Cobertura Sanitaria Teórica: Análisis de Voronoi

Tras la visión general de la concentración de accidentes, el siguiente paso fue analizar la distribución de la infraestructura de respuesta de emergencia. Para ello, se generó un diagrama de Voronoi a partir de la ubicación de los hospitales de Madrid. Como se explicó en la metodología, este mapa (Figura 4.9) particiona la ciudad en “áreas de captación”, donde cada polígono representa la zona geográfica más cercana a un hospital determinado, asumiendo una distancia en línea recta (euclídea).




Figura 4.9: Diagrama de Voronoi de los hospitales de Madrid, mostrando las áreas teóricas de servicio. [Explorar el mapa interactivo en CARTO.](#)

Análisis e Interpretación: La visualización de las celdas de Voronoi permite extraer varias conclusiones sobre la distribución teórica de la cobertura sanitaria:

- **Alta Densidad de Cobertura en el Núcleo Central:** La almendra central de Madrid muestra una alta densidad de hospitales, lo que resulta en celdas de Voronoi

de tamaño reducido. Esto sugiere que, teóricamente, los residentes de esta zona disfrutaban de una mayor proximidad a múltiples centros sanitarios.

- **Disparidad en la Cobertura Periférica:** A medida que nos alejamos del centro, las celdas de Voronoi aumentan drásticamente de tamaño. Se identifican áreas muy extensas en el noroeste (zona de El Pardo), noreste y sur del municipio que son cubiertas por un único hospital. Esto evidencia una considerable disparidad en la proximidad teórica a la atención sanitaria entre el centro y la periferia.
- **Identificación de “Desiertos” Teóricos:** Las grandes celdas periféricas señalan “desiertos” de proximidad, es decir, vastas áreas donde la distancia en línea recta al centro sanitario más cercano es significativamente mayor.

Limitación del Método y Transición al Siguiente Análisis: Si bien este mapa es muy útil para una primera evaluación, su principal limitación es que se basa en la distancia euclídea, ignorando factores cruciales como la red de carreteras, los sentidos de circulación o el tráfico. Un punto puede estar geográficamente cerca de un hospital, pero ser de difícil acceso. Por tanto, para obtener una visión más realista de la accesibilidad, es imprescindible realizar un análisis basado en tiempos de viaje, como el que se presenta en la siguiente sección.

Síntesis 3D: Análisis Multidimensional de Riesgo y Cobertura

Se generaron dos mapas de síntesis 3D para visualizar de forma integrada la relación entre diferentes tipos de riesgo y la calidad de la cobertura sanitaria. En ambos mapas, el **color** de cada hexágono representa el tiempo de respuesta hospitalaria (verde para rápido, rojo para lento), mientras que la **altura** representa una métrica de riesgo específica.

Análisis del Mapa de Severidad

El primer mapa, presentado en la Figura 4.10, utiliza la métrica `severidad_alta` (número de accidentes graves o fatales) para definir la altura de los hexágonos. La visualización tridimensional de la severidad permite extraer varias conclusiones clave:

- **Concentración del Riesgo Grave:** Los “picos” más altos se concentran de forma abrumadora en el núcleo central de la ciudad, coincidiendo con la zona de mejor cobertura sanitaria (color verde). Esto confirma la “paradoja de la densidad”: la zona más peligrosa es también la mejor cubierta.
- **Identificación de Puntos Críticos:** Al filtrar interactivamente el mapa para aislar los puntos de máxima vulnerabilidad (alta severidad y mala cobertura), el hallazgo es significativo. Se identificaron únicamente **dos hexágonos** que contenían accidentes graves y se encontraban en la zona de cobertura de 10 a 15 minutos, y ninguno en la franja de 15 a 30 minutos. Este resultado, aunque numéricamente pequeño, es crucial, pues señala puntos negros muy específicos que requieren una atención prioritaria por su combinación de alto peligro y lenta respuesta.




Figura 4.10: Mapa 3D de Severidad vs. Cobertura. La altura representa el número de accidentes graves/fatales y el color, el tiempo de respuesta hospitalaria. [Explorar el mapa interactivo en CARTO](#).

Análisis del Mapa Riesgo Peatonal

El segundo mapa, mostrado en la Figura 4.11, utiliza la métrica `riesgo_peatonal` (número de atropellos) para la altura. Esta vista ofrece una perspectiva complementaria y diferenciada.




Figura 4.11: Mapa 3D de Riesgo Peatonal vs. Cobertura. La altura representa el número de atropellos y el color, el tiempo de respuesta. [Explorar el mapa interactivo en CARTO](#).

La comparación de este mapa con el de severidad revela patrones distintos:

- **Patrones de Riesgo Diferenciados:** Si bien el riesgo peatonal también se concentra en el centro, la distribución de sus “picos” es distinta a la de la severidad general. Los puntos calientes de atropellos se alinean más con grandes ejes comerciales y zonas de alta densidad peatonal, mientras que los de severidad general pueden estar más ligados a vías rápidas.

- **Ausencia de Atropellos en “Zonas de Sombra”:** Un hallazgo fundamental y muy positivo se revela al filtrar por las peores zonas de cobertura. No se registra **ningún atropello a peatón** en zonas con un tiempo de respuesta superior a 15 minutos. Esto sugiere que el riesgo peatonal, uno de los más críticos, está geográficamente contenido dentro de las áreas con un acceso más rápido a los servicios de emergencia.

Conclusión Estratégica del Análisis Multidimensional

La comparación de estos dos mapas 3D ofrece una visión estratégica clara que se puede resumir en una **doble intervención**:

- **En el centro de la ciudad, el desafío es la prevención.** Los análisis demuestran que las zonas con mayor concentración de riesgo, tanto por severidad general como por atropellos, son precisamente las que gozan de una cobertura sanitaria óptima. Por lo tanto, las políticas deben centrarse en reducir la ocurrencia de incidentes mediante medidas de reducción de la velocidad, rediseño de intersecciones y una mayor protección para los peatones.
- **En la periferia, el desafío es la optimización de la respuesta para casos críticos.** Aunque el riesgo general es bajo, se han identificado puntos específicos de alta severidad en zonas con tiempos de respuesta más lentos. La prioridad aquí es optimizar las rutas de emergencia hacia estos “puntos negros” aislados. No obstante, es un hallazgo muy positivo que el riesgo de atropello, uno de los más críticos, está geográficamente contenido en las zonas de buena cobertura, siendo prácticamente nulo en las áreas periféricas con peor accesibilidad.

Validación Estadística: Detección de Hotspots y Clústeres con LISA

Como paso final del análisis espacial, y para validar estadísticamente los patrones visuales identificados, se aplicaron los estadísticos LISA (Getis-Ord G_i^* y Local Moran's I) sobre el volumen de accidentes por hexágono (resolución H9). Este análisis se presenta en dos etapas: primero, los resultados brutos de los estadísticos y, segundo, los resultados filtrados para mostrar únicamente los patrones con significancia estadística.

Resultados Brutos de los Estadísticos LISA

La Figura 4.12 muestra la distribución completa de los valores de los estadísticos para cada hexágono del área de estudio.

A simple vista, el mapa de Getis-Ord (izquierda) ya sugiere un patrón claro, con valores altos (rojos, indicativos de hotspots) concentrados en el centro y valores bajos (azules, indicativos de coldspots) en la periferia. El mapa de Local Moran's I (derecha) también muestra una predominancia de hexágonos High-High (rojo) y Low-Low (marrón). Sin embargo, en esta fase, no podemos saber si estos patrones son estadísticamente significativos o si podrían haber ocurrido por puro azar.




Figura 4.12: Resultados brutos del análisis LISA. Izquierda: Getis-Ord G_i^* . Derecha: Local Moran's I. [Explorar el mapa interactivo en CARTO](#).

Resultados Estadísticamente Significativos ($p < 0.05$)

El paso crucial del análisis es filtrar estos resultados para conservar únicamente aquellos hexágonos cuyo patrón es estadísticamente significativo, con un nivel de confianza del 95 % ($p < 0.05$). La Figura 4.13 muestra el resultado de aplicar este filtro.




Figura 4.13: Resultados del análisis LISA filtrados por significancia estadística ($p < 0.05$). [Explorar el mapa interactivo en CARTO](#).

Análisis e Interpretación: La comparación de ambos mapas revela el poder del análisis de significancia:

- **Confirmación de Patrones Robustos:** El filtro estadístico no altera la estructura general del patrón, sino que la “limpia” y la valida. Se confirma la existencia de un masivo y significativo **hotspot** (Getis-Ord) y un clúster **High-High** (Moran's I) que domina la almendra central de Madrid. De igual manera, se validan los **clústeres Low-Low** de la periferia, que se corresponden con los coldspots.

- **El Poder de la Comparación:** El Local Moran's I (derecha) aporta matices que el Getis-Ord no captura. Mientras que el Getis-Ord dibuja un gran “mar” de hotspots, el Moran's I es más selectivo, identificando el verdadero núcleo del clúster High-High. Además, revela la existencia de **atípicos (outliers) espaciales Low-High** (azul claro), que son “islas de seguridad” estadísticamente significativas dentro de la zona de alta siniestralidad. Estos puntos son de gran interés analítico, pues pueden corresponder a grandes parques o zonas peatonales que actúan como cortafuegos del riesgo.
- **Conclusión Final:** El análisis LISA no solo confirma visualmente el patrón de concentración de accidentes en el centro de Madrid, sino que le otorga validez estadística. Demuestra que la siniestralidad en la ciudad no es un fenómeno aleatorio, sino que responde a una fuerte autocorrelación espacial, con un núcleo de alta peligrosidad y una periferia de baja incidencia claramente definidos.

Diagnóstico de Precisión: Identificación del “Efecto Arterial” a Escala H10

Con el objetivo de explorar los patrones de siniestralidad al máximo nivel de detalle posible, se realizó un análisis LISA adicional a una resolución superior (H10). Como se anticipó en la metodología, este aumento de la granularidad presentó desafíos computacionales significativos.

La Figura 4.14 muestra los resultados brutos. Si bien el Local Moran's I no pudo ser validado estadísticamente debido a la imposibilidad de ejecutar un número suficiente de permutaciones, el análisis de Getis-Ord G_i^* sí arrojó resultados significativos.



Figura 4.14: Resultados brutos del análisis LISA a resolución H10. La limitación computacional impide la validación del Local Moran's I. [Explorar el mapa interactivo en CARTO.](#)

Al aplicar el filtro de significancia estadística ($p < 0.05$) únicamente sobre el estadístico Getis-Ord G_i^* , se obtiene una visión sin precedentes del “esqueleto” del riesgo vial en Madrid (Figura 4.15).

Análisis e Interpretación: Este mapa de micro-hotspots revela patrones que no eran visibles a una resolución inferior:




Figura 4.15: Hotspots de accidentalidad estadísticamente significativos ($p < 0.05$) a resolución H10. El enlace interactivo corresponde al mapa de la Figura 4.14, aplicando un filtro de $p_value < 0.05$.

- **El “Efecto Arterial”:** Los hotspots significativos se alinean con una precisión quirúrgica sobre las principales arterias viales de la ciudad. El trazado de la M-30 es perfectamente discernible, así como los grandes ejes que vertebran la ciudad, como el Paseo de la Castellana. Esto confirma que el riesgo sistémico se concentra en la red vial principal.
- **Identificación de Nudos Críticos:** A esta escala, los clústeres más intensos (rojo oscuro) ya no son barrios, sino que se corresponden con nudos viales específicos: grandes intersecciones, rotondas complejas y accesos a las autopistas. El análisis a H10 permite la identificación de “puntos negros” con una gran precisión geográfica.
- **Conclusión Principal:** El análisis a resolución H10, aunque limitado, proporciona una evidencia poderosa de que los hotspots de accidentalidad están intrínsecamente ligados al flujo, la densidad y la complejidad de la red de tráfico principal. Sirve como una herramienta de diagnóstico de alta precisión para localizar los puntos exactos que requerirían una auditoría de seguridad vial.

Análisis de Puntos Negros: Detección de Clústeres de Alta Densidad con DBSCAN

Como análisis final, la aplicación del algoritmo DBSCAN con parámetros de alta exigencia permitió trascender la identificación de “zonas” para localizar los “nodos” exactos de la infraestructura vial que actúan como catalizadores de la siniestralidad. El resultado es un mapa de 248 “puntos negros” o clústeres de muy alta densidad.

La Figura 4.16 muestra estos clústeres como polígonos, permitiendo analizar su forma y ubicación precisa.




Figura 4.16: Clústeres de alta densidad (“puntos negros”) identificados con DBSCAN. Cada polígono representa una intersección o nudo vial con una concentración extrema de accidentes. [Explorar el mapa interactivo en CARTO.](#)

Análisis e Interpretación: El resultado de este análisis de alta precisión es extraordinariamente revelador:

- **El Riesgo se Cristaliza en las Intersecciones:** El mapa demuestra de forma contundente que las concentraciones más extremas de accidentes se localizan casi exclusivamente en **intersecciones, cruces y rotondas**. El algoritmo ha filtrado eficazmente las vías para resaltar los puntos exactos donde los flujos de tráfico entran en conflicto.
- **Diagnóstico a Nivel de Clúster:** La potencia de este análisis reside en la capacidad de diagnosticar cada punto negro individualmente. Por ejemplo, el clúster más grande, con **377 accidentes**, se localiza en la intersección de la Avenida de la Albufera con la Avenida de la Paz (M-30). Al explorar su perfil detallado a través del pop-up interactivo, se puede observar que el 50.6% de los incidentes son colisiones dobles y un 28% son alcances, ofreciendo pistas claras sobre posibles fallos en el diseño o la señalización de dicho cruce.
- **Herramienta para la Priorización:** La combinación del mapa con los widgets interactivos (que permiten filtrar por número total de accidentes o por tipo) con-

vierte esta visualización en una herramienta estratégica. Permite a los gestores urbanos no solo ver dónde están los problemas, sino también priorizarlos según diferentes criterios: se pueden aislar los 10 peores cruces por volumen total, o los 5 peores en cuanto a seguridad peatonal, para focalizar los recursos de intervención.

Conclusión Principal: Este análisis final con DBSCAN cierra el ciclo de investigación. Se ha pasado de una visión macro (distritos y patrones generales) a una visión de precisión micro (hotspots en la red vial) y, finalmente, a un diagnóstico de nodos de infraestructura específicos. Se proporciona así una hoja de ruta clara y basada en datos para la implementación de auditorías de seguridad vial con el mayor impacto posible.

Discusión, Conclusiones y Líneas Futuras

Este capítulo final tiene como objetivo sintetizar los hallazgos del presente trabajo, contextualizarlos en un marco más amplio, y proponer caminos para futuras investigaciones. Se comienza con una discusión integrada de los resultados, seguida de las conclusiones principales extraídas y, finalmente, se indican posibles extensiones del trabajo realizado.

5.1 Discusión de Resultados

El análisis exhaustivo de la siniestralidad vial en Madrid ha revelado que este fenómeno, lejos de ser aleatorio, presenta una estructura espacial y temporal muy definida. La combinación de técnicas de visualización exploratoria en Tableau y modelado geoespacial avanzado en CARTO ha permitido no solo cuantificar el problema, sino también comprender su compleja geografía.

El punto de partida estadístico fue la confirmación de una fuerte autocorrelación espacial global (I de Moran = 0.53), que validó la hipótesis de que los accidentes en Madrid tienden a agruparse. A partir de esta premisa, el hallazgo más contundente es la **extrema concentración del riesgo en el núcleo central de la ciudad**. Los análisis exploratorios por distrito ya apuntaban a esta tendencia, pero fueron los análisis de clústeres y, especialmente, el de hotspots a resolución H10, los que validaron estadísticamente este patrón. El “efecto arterial” observado en el mapa de micro-hotspots (Figura 4.15) confirma que el riesgo sistémico está intrínsecamente ligado a la red vial principal (e.g., M-30, Paseo de la Castellana), donde se concentran el flujo, la densidad y la complejidad vehicular.

Uno de los resultados más reveladores es lo que hemos denominado la “**paradoja de la densidad**”. Los análisis 3D demostraron que las zonas con la mayor concentración de accidentes graves y de atropellos a peatones son, afortunadamente, las que gozan de la mejor cobertura sanitaria en términos de tiempo de respuesta. Este hallazgo sugiere un desacoplamiento entre las causas de la siniestralidad (ligadas a la infraestructura y movilidad urbana) y la eficacia de la respuesta de emergencia (ligada a la ubicación de la red hospitalaria). Mientras que la respuesta es óptima en el centro, el riesgo persiste, lo que apunta a la necesidad de políticas de prevención.

Asimismo, el análisis de vulnerabilidad ha sido esclarecedor. Los datos de Tableau mostraron que peatones y usuarios de vehículos de dos ruedas sufren consecuencias desproporcionadamente graves. El análisis 3D de riesgo peatonal confirmó que este problema se concentra en el centro, pero, de forma muy positiva, está geográficamente contenido dentro de las áreas con mejor acceso a emergencias, ya que no se registraron atropellos en las zonas de peor cobertura (>15 minutos).

Finalmente, el análisis con DBSCAN permitió trascender la identificación de “zonas” para ofrecer un diagnóstico de precisión a nivel de nodo vial. La localización de 248 “puntos negros” en intersecciones y rotondas específicas demuestra que el riesgo extremo se cristaliza en puntos de conflicto de infraestructura, proporcionando una hoja de ruta accionable para auditorías de seguridad vial.

Finalmente, es crucial reconocer las **limitaciones del estudio**. La principal es la ausencia de datos de aforo o intensidad de tráfico. Sin esta variable, no es posible nor-

malizar el riesgo. Un gran número de accidentes en una vía principal podría deberse simplemente a su enorme volumen de tráfico, o podría indicar que la vía es intrínsecamente peligrosa. Esta distinción es fundamental para una asignación de recursos eficiente y sigue siendo una pregunta abierta.

5.2 Conclusiones Principales

De la discusión anterior, se derivan las siguientes conclusiones fundamentales:

1. **La siniestralidad vial en Madrid presenta una fuerte y significativa autocorrelación espacial.** El riesgo no es un fenómeno homogéneo, sino que se organiza en un patrón claro de un núcleo de alta peligrosidad y una periferia de baja incidencia, validado tanto visual como estadísticamente.
2. **Existe una dualidad en la naturaleza del riesgo que exige una estrategia de intervención diferenciada.** El problema en el centro de la ciudad es de **prevención** (alto riesgo, buena cobertura), mientras que en el arco periférico es de **optimización de la respuesta** para los escasos pero críticos puntos de alta severidad que caen en “zonas de sombra” sanitarias.
3. **El riesgo se cristaliza en nodos de infraestructura específicos.** El análisis de alta precisión con DBSCAN demuestra que las concentraciones más extremas de accidentes no ocurren a lo largo de las vías, sino en puntos de conflicto como intersecciones y rotondas, proporcionando objetivos claros para intervenciones de ingeniería vial.
4. **La vulnerabilidad es un factor clave en la gravedad de los accidentes.** Los peatones y los usuarios de vehículos de dos ruedas (motocicletas, patinetes) presentan un riesgo desproporcionadamente alto de sufrir lesiones graves o fatales, aun cuando no sean el grupo más numeroso de implicados.
5. **La accesibilidad hospitalaria, medida por tiempo de viaje, es un indicador más realista que la proximidad euclídea.** La comparativa de isócronas e isodistancias y su posterior aplicación en los modelos de riesgo ha demostrado ser una metodología robusta para evaluar la cobertura sanitaria real.

5.3 Líneas Futuras de Investigación

El presente trabajo abre la puerta a múltiples vías de investigación para profundizar en la comprensión de la seguridad vial en entornos urbanos. Se proponen las siguientes líneas futuras:

- **Incorporación de datos de intensidad de tráfico:** Como se ha discutido, el paso futuro más crucial sería cruzar los hotspots de siniestralidad con datos de Intensidad Media Diaria (IMD) para normalizar el riesgo. Esto permitiría responder a la pregunta: ¿esta calle tiene muchos accidentes porque tiene mucho tráfico, o es intrínsecamente peligrosa incluso para el tráfico que soporta?

- **Aplicación de Regresión Geográficamente Ponderada (GWR):** Habiendo establecido la existencia de patrones espaciales, el siguiente paso lógico sería aplicar modelos GWR para explorar la no estacionariedad de los factores de riesgo. Se podría investigar si la influencia de variables como la presencia de un carril bici, el tipo de intersección o las condiciones meteorológicas varía geográficamente.
- **Análisis Espacio-Temporal Detallado:** Aunque se ha introducido el concepto, se podría implementar un análisis de hotspots emergentes completo para identificar tendencias dinámicas, como zonas que se están volviendo más peligrosas con el tiempo o, por el contrario, áreas donde las intervenciones han tenido éxito y el riesgo está en declive.
- **Enriquecimiento con Variables del Entorno Construido:** Se podrían incorporar más variables del entorno, como el uso del suelo (comercial, residencial), la ubicación de centros de ocio nocturno, colegios, o la calidad de la infraestructura peatonal, para construir modelos explicativos más sofisticados.
- **Análisis del impacto de cámaras y radares:** Incorporar las ubicaciones de los dispositivos de control de tráfico para estudiar su efecto en la reducción de la siniestralidad en sus zonas de influencia, cruzando esta información con los hotspots identificados.

Bibliografía

- [Ans95] L. Anselin, “Local indicators of spatial association—lisa,” *Geographical Analysis*, vol. 27, no. 2, pp. 93–115, 1995.
- [Ayu25] Ayuntamiento de Madrid. (2025) Accidentes de tráfico. Portal de Datos Abiertos. [Online]. Available: <https://datos.madrid.es/portal/site/egob/menuitem.c05c1f754a33a9fbe52ae52459437a5a/?vgnnextoid=7c2121fe183fa410VgnVCM1000000b205a0aRCRD&vgnnextchannel=374512b9ace9f310VgnVCM100000171f5a0aRCRD>
- [BPGR13] R. S. Bivand, E. Pebesma, and V. Gomez-Rubio, *Applied Spatial Data Analysis with R*, 2nd ed. New York: Springer, 2013.
- [DBCvKO08] M. De Berg, O. Cheong, M. van Kreveld, and M. Overmars, *Computational Geometry: Algorithms and Applications*, 3rd ed. Springer-Verlag, 2008.
- [dC16] M. P. do Carmo, *Differential Geometry of Curves and Surfaces: Revised and Updated Second Edition*. Mineola, New York: Dover Publications, 2016.
- [EK SX96] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, “A density-based algorithm for discovering clusters in large spatial databases with noise,” in *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96)*, 1996, pp. 226–231.
- [FBC02] A. S. Fotheringham, C. Brunsdon, and M. Charlton, *Geographically Weighted Regression: The Analysis of Spatially Varying Relationships*. John Wiley & Sons, 2002.
- [GO92] A. Getis and J. K. Ord, “The analysis of spatial association by use of distance statistics,” *Geographical Analysis*, vol. 24, no. 3, pp. 189–206, 1992.
- [H3 24] H3 Geospatial Foundation. (2024) H3: A hexagonal hierarchical geospatial indexing system. [Online]. Available: <https://h3geo.org/>
- [HTF09] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer, 2009.
- [McK22] H. McKenzie, “Spatial indexes 101: The low-code edition,” CARTO, Report, 2022.
- [McK23] ——. (2023) A complete guide to space-time hotspot analysis. CARTO Blog. [Online]. Available: <https://carto.com/blog/space-time-hotspots-guide>
- [Mor50] P. A. P. Moran, “Notes on continuous stochastic phenomena,” *Biometrika*, vol. 37, no. 1/2, pp. 17–23, 1950.

- [OBSC00] A. Okabe, B. Boots, K. Sugihara, and S. N. Chiu, *Spatial Tessellations: Concepts and Applications of Voronoi Diagrams*, 2nd ed. Wiley, 2000.
- [OG95] J. K. Ord and A. Getis, “Local spatial autocorrelation statistics: Distributional issues and an application,” *Geographical Analysis*, vol. 27, no. 4, pp. 286–306, 1995.
- [R C23] R Core Team, *R: A Language and Environment for Statistical Computing*, R Foundation for Statistical Computing, Vienna, Austria, 2023. [Online]. Available: <https://www.R-project.org/>
- [Ube18] Uber Engineering. (2018) H3: Uber’s hexagonal hierarchical spatial index. [Online]. Available: <https://www.uber.com/en-GB/blog/h3/>

Apéndices

Código y Campos Calculados

A.1 Script de Preprocesamiento en R

```

1 #####
2 # LIBRERÍAS
3 #####
4 library(dplyr)
5 library(lubridate)
6 library(hms)
7 library(sf)
8 library(terra)
9 library(geojsonio)
10 library(readr)
11 library(tidyr)
12 library(parzer)
13 library(forcats)
14
15 #####
16 # DIRECTORIO DE TRABAJO
17 #####
18 setwd("C:/Users/Jorge/OneDrive/TFG_Location_Intelligence/data")
19
20 # Inicializar listas para acumulación
21 # accidentes_all <- list()
22 # implicados_all <- list()
23 accidentalidad_sin_distrito_all <- list()
24
25 for (año in 2019:2025) {
26   archivo <- paste0("raw/Accidentalidad/", año, "_Accidentalidad.csv")
27   if (file.exists(archivo)) {
28     df <- read_delim(archivo, delim = ";", locale = locale(encoding = "UTF
29     -8"),
30                       col_types = cols(num_expediente = col_character()))
31
32     valores_na <- c("NULL", "", "Se desconoce", "Sin especificar", "
33     Desconocido", "#¡VALOR!")
34
35     # FILTRADO TEMPRANO
36     df <- df %>%
37       filter(!is.na(num_expediente)) %>%
38       mutate(
39         coordenada_x_utm = suppressWarnings(as.numeric(coordenada_x_utm)),
40         coordenada_y_utm = suppressWarnings(as.numeric(coordenada_y_utm))
41       ) %>%
42       filter(!is.na(coordenada_x_utm), !is.na(coordenada_y_utm))
43
44     df_limpio <- df %>%
45       mutate(across(where(is.character), ~ ifelse(. %in% valores_na, NA_
46       character_, .))) %>%
47       mutate(
48         fecha_f = dmy(fecha),
49         horas = hour(hms::as_hms(as.character(hora))),
50         hora_rango = case_when(
51           horas < 6 ~ "mañana",

```

```

49     horas < 12 ~ "mañana",
50     horas < 18 ~ "tarde",
51     horas <= 23 ~ "noche",
52     TRUE ~ NA_character_
53   ),
54   anno = factor(year(fecha_f), ordered = TRUE),
55   mes = month(fecha_f, label = TRUE, abbr = FALSE),
56   dia_mes = factor(day(fecha_f), ordered = TRUE),
57   dia_semana = wday(fecha_f, label = TRUE, abbr = FALSE),
58   horas = factor(horas, ordered = TRUE),
59   hora_rango = factor(hora_rango, levels = c("madrugada", "mañana", "
tarde", "noche"), ordered = TRUE),
60   num_expediente = factor(num_expediente),
61   lesividad = fct_explicit_na(lesividad, "Lesividad Desconocida"),
62   lesividad_clasificada = factor(case_when(
63     lesividad %in% c(
64       "Asistencia sanitaria ambulatoria con posterioridad",
65       "Asistencia sanitaria inmediata en centro de salud o mutua",
66       "Asistencia sanitaria sólo en el lugar del accidente",
67       "Atención en urgencias sin posterior ingreso",
68       "Ingreso inferior o igual a 24 horas"
69     ) ~ "HERIDOS LEVES",
70     lesividad == "Ingreso superior a 24 horas" ~ "HERIDOS GRAVES",
71     lesividad == "Fallecido 24 horas" ~ "FALLECIDOS",
72     lesividad == "Sin asistencia sanitaria" ~ "SIN ASISTENCIA /
ILESOS",
73     lesividad == "Lesividad Desconocida" ~ "LESIVIDAD DESCONOCIDA",
74     TRUE ~ "LESIVIDAD DESCONOCIDA"
75   ), levels = c("SIN ASISTENCIA / ILESOS", "HERIDOS LEVES", "HERIDOS
GRAVES", "FALLECIDOS", "LESIVIDAD DESCONOCIDA"), ordered = TRUE),
76   estado_meteorológico = fct_explicit_na(estado_meteorológico, "
Desconocido"),
77   sexo = fct_explicit_na(sexo, "No Especificado"),
78   tipo_persona = fct_explicit_na(tipo_persona, "No Especificado"),
79   rango_edad = factor(fct_explicit_na(rango_edad, "No Especificado"),
80     levels = c("Menor de 5 años", "De 6 a 9 años",
81     "De 10 a 14 años", "De 15 a 17 años",
82     "De 18 a 20 años", "De 21 a 24 años"
83     , "De 25 a 29 años", "De 30 a 34 años",
84     "De 35 a 39 años", "De 40 a 44 años"
85     , "De 45 a 49 años", "De 50 a 54 años",
86     "De 55 a 59 años", "De 60 a 64 años"
87     , "De 65 a 69 años", "De 70 a 74 años",
88     "Más de 74 años", "No Especificado")
89   , ordered = TRUE),
90   tipo_vehiculo = fct_explicit_na(tipo_vehiculo, "No Especificado"),
91   tipo_vehiculo_clasificado = factor(case_when(
92     tipo_vehiculo %in% c("Motocicleta > 125cc", "Motocicleta hasta
125cc",
93     "Moto de tres ruedas > 125cc", "Moto de tres
ruedas hasta 125cc") ~ "Motocicleta",
94     tipo_vehiculo %in% c("Ciclomotor", "Ciclomotor de dos ruedas L1e-
B", "Ciclomotor de tres ruedas") ~ "Ciclomotor",
95     tipo_vehiculo %in% c("Bicicleta", "Ciclo", "Bicicleta EPAC (
pedaleo asistido)") ~ "Bicicleta",
96     tipo_vehiculo %in% c("Patinete", "Patinete no eléctrico") ~ "
Patinete",

```

```

122     tipo_vehiculo %in% c("Camión rígido", "Tractocamión", "Vehículo
123 articulado") ~ "Camión",
124     tipo_vehiculo %in% c("Autobús", "Autobús articulado", "Autobus
125 EMT", "Autobús articulado EMT",
126         "Microbús <= 17 plazas") ~ "Autobús",
127     tipo_vehiculo %in% c("Turismo", "Todo terreno", "Furgoneta") ~ "
128 Turismo/Furgoneta",
129     tipo_vehiculo %in% c("Tren/metro", "Tranvía") ~ "Transporte
130 ferroviario",
131     tipo_vehiculo %in% c("Ambulancia SAMUR") ~ "Ambulancia",
132     tipo_vehiculo %in% c("Maquinaria agrícola", "Maquinaria de obras"
133 ) ~ "Maquinaria",
134     tipo_vehiculo %in% c("Remolque", "Semiremolque", "Caravana") ~ "
135 Remolques/Caravanas",
136     tipo_vehiculo %in% c("VMU eléctrico") ~ "Vehículo movilidad
137 urbana",
138     tipo_vehiculo %in% c("Otros vehículos con motor", "Otros vehí
139 culos sin motor") ~ "Otros",
140     tipo_vehiculo == "No Especificado" ~ "No Especificado",
141     TRUE ~ "Otros"
142 ), ordered = FALSE),
143 positiva_alcohol = fct_explicit_na(as.character(positiva_alcohol),
144 "N"),
145 positiva_droga = fct_explicit_na(as.character(positiva_droga), "0")
146 ,
147     tipo_accidente = fct_explicit_na(tipo_accidente, "No Especificado")
148 ,
149     tipo_accidente_clasificado = factor(case_when(
150         tipo_accidente %in% c("Colisión frontal", "Colisión fronto-
151 lateral", "Colisión lateral") ~ "Colisión doble",
152         tipo_accidente == "Colisión múltiple" ~ "Colisión múltiple",
153         tipo_accidente == "Alcance" ~ "Alcance",
154         tipo_accidente == "Choque contra obstáculo fijo" ~ "Choque contra
155 obstáculo",
156         tipo_accidente == "Atropello a persona" ~ "Atropello a persona",
157         tipo_accidente == "Vuelco" ~ "Vuelco",
158         tipo_accidente == "Caída" ~ "Caída",
159         tipo_accidente %in% c("Atropello a animal", "Despeñamiento", "
160 Solo salida de la vía", "Otro") ~ "Otras causas",
161         tipo_accidente == "No Especificado" | is.na(tipo_accidente) ~ "No
162 especificado",
163         TRUE ~ "No especificado"
164     ))
165 )
166
167 # Crear objeto espacial
168 accidentalidad_sf <- df_limpio %>%
169     st_as_sf(coords = c("coordenada_x_utm", "coordenada_y_utm"), crs =
170 32630) %>%
171     st_transform(crs = 4326)
172
173 # accidentes <- accidentalidad_sf %>%
174 #     select(num_expediente, fecha = fecha_f, tipo_accidente_clasificado,
175 # estado_meteorológico,
176 #         anno, mes, dia_mes, dia_semana, horas, hora_rango, geometry)
177 # %>%
178 #     distinct(num_expediente, .keep_all = TRUE)

```



```

131
132   # implicados <- df_limpio %>%
133   #   select(num_expediente, tipo_vehiculo_clasificado, tipo_persona,
134   #         rango_edad, sexo,
135   #         lesividad_clasificada, positiva_alcohol, positiva_droga)
136
137   accidentalidad_sin_distrito <- accidentalidad_sf %>%
138     select(num_expediente, fecha = fecha_f, tipo_accidente_clasificado,
139           estado_meteorológico,
140           anno, mes, dia_mes, dia_semana, horas, hora_rango,
141           tipo_vehiculo_clasificado, tipo_persona, rango_edad, sexo,
142           lesividad_clasificada, positiva_alcohol, positiva_droga,
143           geometry)
144
145   # Guardar en listas
146   # accidentes_all[[as.character(año)]] <- accidentes
147   # implicados_all[[as.character(año)]] <- implicados
148   accidentalidad_sin_distrito_all[[as.character(año)]] <- accidentalidad_
149   sin_distrito
150
151   # # Guardar resultados del año
152   # st_write(accidentes, file.path("processed", paste0("accidentes_", año
153   # , ".geojson")), delete_dsn = TRUE)
154   # write_csv(st_drop_geometry(victimas), file.path("processed", paste0("
155   victimas_", año, ".csv")))
156   # st_write(datos_limpios, file.path("processed", paste0("datos_limpios_
157   ", año, ".geojson")), delete_dsn = TRUE)
158
159   message("Año ", año, " procesado y guardado correctamente.")
160 } else {
161   warning("Archivo no encontrado para el año ", año)
162 }
163 }
164
165 # Unir todos los años
166 # accidentes <- do.call(rbind, accidentes_all)
167 # implicados <- bind_rows(implicados_all)
168 accidentalidad_sin_distrito <- do.call(rbind, accidentalidad_sin_distrito_
169   all)
170
171 # Guardar
172 # st_write(accidentes, "processed/accidentes.geojson", delete_dsn = TRUE)
173 # write_csv(implicados, "processed/imPLICADOS.csv")
174 st_write(accidentalidad_sin_distrito, "processed/accidentalidad_sin_
175   distrito.geojson", delete_dsn = TRUE)
176
177 #####
178 # CARGA Y FILTRADO DE DISTRITOS
179 #####
180 distritos <- st_read("raw/Distritos/madrid-districts_.geojson", quiet =
181   TRUE) %>%
182   rename(distrito = name) %>%
183   mutate(distrito = as.factor(distrito)) %>%
184   select(distrito, geometry)
185

```

```

178 st_write(distributos, "processed/distributos.geojson", driver = "GeoJSON",
179         delete_dsn = TRUE)
180
181 #####
182 # CARGA Y FILTRADO DE RADARES
183 #####
184 # Leer CSV original
185 df_radars_csv <- read_delim("raw/Radars/RADARES_FIJOS_vDTT (1).csv",
186                             delim = ";",
187                             locale = locale(encoding = "UTF-8"),
188                             show_col_types = FALSE) %>%
189   rename(
190     Velocidad_limite = `Velocidad límite`,
191     Longitud_inicio_tramo = `Longitud inicio tramo`,
192     Latitud_inicio_tramo = `Latitud inicio tramo`
193   )
194
195
196 # Filtrar radars fijos y convertir a sf
197 radars_fijos_sf <- df_radars_csv %>%
198   filter(Tipo == "Fijo") %>%
199   select( Velocidad_limite, Longitud, Latitud) %>%
200   st_as_sf(coords = c("Longitud", "Latitud"), crs = 4326)
201
202 # Guardar como GeoJSON
203 st_write(radars_fijos_sf, "processed/radars_fijos.geojson", driver = "
204         GeoJSON", delete_dsn = TRUE)
205
206
207
208 #####
209 # CARGA Y FILTRADO DE CÁMARAS
210 #####
211
212 # Cámaras CCTV (desde KML)
213 kml_data_camaras <- st_read("raw/Camaras/CCTV.kml", quiet = TRUE)
214 camaras_cctv <- kml_data_camaras[st_geometry_type(kml_data_camaras) == "
215     POINT", ] %>%
216   st_zm(drop = TRUE, what = "ZM") %>% # Elimina Z y M si existen
217   mutate(tipo = "CCTV") %>%
218   select(tipo, geometry)
219
220
221 # Cámaras ZBE (desde CSV con coordenadas UTM)
222 df_camaras_ZBE_csv <- read_delim("raw/Camaras/camaras_ZBE.csv", delim = ";"
223     , locale = locale(encoding = "UTF-8"))
224 camaras_zbe <- df_camaras_ZBE_csv %>%
225   mutate(
226     utm_x_calc = suppressWarnings(as.numeric(utm_x)),
227     utm_y_calc = suppressWarnings(as.numeric(utm_y))
228   ) %>%
229   filter(!is.na(utm_x_calc) & !is.na(utm_y_calc) & utm_x_calc != 0 & utm_y_
230     calc != 0) %>%

```

```

230   st_as_sf(coords = c("utm_x_calc", "utm_y_calc"), crs = 32630) %>%
231   st_transform(crs = 4326) %>%
232   mutate(tipo = "ZBE")%>%
233   select(tipo, geometry)
234
235
236 # Cámaras ZBEDEP (desde CSV con long/lat)
237 df_camaras_ZBEDEP_csv <- read_delim("raw/Camaras/camaras_ZBEDEP.csv", delim
    = ";", locale = locale(encoding = "UTF-8"))
238 camaras_zbedep <- df_camaras_ZBEDEP_csv %>%
239   st_as_sf(coords = c("longitud", "latitud"), crs = 4326) %>%
240   mutate(tipo = "ZBEDEP")%>%
241   select(tipo, geometry)
242
243
244 # Unir todas las cámaras
245 camaras <- bind_rows(camaras_cctv, camaras_zbe, camaras_zbedep)
246
247
248 # Guardar como único GeoJSON
249 st_write(camaras, "processed/camaras.geojson", driver = "GeoJSON", delete_
    dsn = TRUE)
250
251 # # ---- Guardar como GeoJSON ----
252 # st_write(camaras_cctv, "processed/camaras_cctv.geojson", driver = "
    GeoJSON", delete_dsn = TRUE)
253 # st_write(camaras_zbe, "processed/camaras_zbe.geojson", driver = "
    GeoJSON", delete_dsn = TRUE)
254 # st_write(camaras_zbedep, "processed/camaras_zbedep.geojson", driver = "
    GeoJSON", delete_dsn = TRUE)
255
256
257
258 #####
259 # CARGA Y FILTRADO DE HOSPITALES
260 #####
261 # Leer CSV original
262 df_hospitales_csv <- read.csv2("raw/Hospitales/hospitales_50.csv", encoding
    = "UTF-8")
263
264 # Seleccionar y convertir coordenadas UTM a numérico
265 hospitales_geom <- df_hospitales_csv %>%
266   mutate(
267     x = suppressWarnings(as.numeric(as.character(COORDENADA.X))),
268     y = suppressWarnings(as.numeric(as.character(COORDENADA.Y)))
269   ) %>%
270   filter(!is.na(x) & !is.na(y)) %>%
271   st_as_sf(coords = c("x", "y"), crs = 32630) %>%
272   st_transform(crs = 4326) %>%
273   select(NOMBRE, geometry) # Solo geometría
274
275 # Guardar como GeoJSON
276 st_write(hospitales_geom, "processed/hospitales.geojson", driver = "GeoJSON
    ", delete_dsn = TRUE)

```

Listing A.1: Script clean_to_CARTO.R

A.2 Scripts SQL de Workflows de CARTO

Workflow de Accidentalidad

```

1  /*
2  Code generated by Carto Workflows Engine (RUN)
3  - workflowid:a412059b-60e0-474c-897f-83aa7f342bc1
4  - versionid:8858c9fea91dfab7
5  - paramsid:97d170e1550eee4a
6  */
7
8  /*===== native.intersection (v1) [3a1d1c84-8dd3-49d6-b37a-8
   e3c9ac84f5c] =====*/
9  BEGIN
10 DECLARE alias STRING;
11
12 EXECUTE IMMEDIATE
13 '''
14   with __alias AS(
15     SELECT CONCAT(
16       'b.', column_name, ' AS ', column_name, '_secondary'
17     ) col_alias
18     FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3`.
19     INFORMATION_SCHEMA.COLUMNS
20     WHERE table_name = 'distritos'
21   )
22   SELECT STRING_AGG(col_alias, ', ')
23   FROM __alias
24 '''
25 INTO alias;
26
27 EXECUTE IMMEDIATE
28 REPLACE(
29   '''DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
30     workflows_temp_jorgekk22_3000e6c3.
31     WORKFLOW_8cb51442ff57d51e_87633ce227709ca8_result`''',
32   '%s',
33   alias
34 );
35
36 EXECUTE IMMEDIATE
37 REPLACE(
38   '''CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
39     workflows_temp_jorgekk22_3000e6c3.
40     WORKFLOW_8cb51442ff57d51e_87633ce227709ca8_result`
41   OPTIONS (
42     expiration_timestamp = TIMESTAMP_ADD(
43       CURRENT_TIMESTAMP(), INTERVAL 30 DAY
44     )
45   )
46   AS
47   SELECT
48     ST_INTERSECTION(
49       b.geom,
50       a.geom
51     )
52     AS intersection_geom_geom,

```

```

47     a.*, %s
48     FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.
accidentalidad_sin_distrito` AS a
49     JOIN `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.districts` AS b
50     ON ST_INTERSECTS(
51         b.geom,
52         a.geom
53     )''',
54     '%s',
55     alias
56 );
57 END;
58
59 /*===== native.dropcolumn (v1) [6a5304bd-f1e0-4ea7-9492-5416
b8e62dae] =====*/
60 BEGIN
61 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_8cb51442ff57d51e_30e9f569e85ef7e2_result`;
62 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_8cb51442ff57d51e_30e9f569e85ef7e2_result`
63 OPTIONS (
64     expiration_timestamp = TIMESTAMP_ADD(
65         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
66     )
67 )
68 AS
69 SELECT * EXCEPT (intersection_geom_geom, geom_secondary)
70 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_8cb51442ff57d51e_87633ce227709ca8_result`;
71 END;
72
73 /*===== native.renamecolumn (v1) [5f459751-5e57-4c59-959c-
c46c2421032a] =====*/
74 BEGIN
75 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_8cb51442ff57d51e_243221859e77d290_result`;
76 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_8cb51442ff57d51e_243221859e77d290_result`
77 OPTIONS (
78     expiration_timestamp = TIMESTAMP_ADD(
79         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
80     )
81 )
82 AS
83 SELECT * EXCEPT (distrito_secondary),
84     distrito_secondary AS distrito
85 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_8cb51442ff57d51e_30e9f569e85ef7e2_result`;
86 END;
87
88 /*===== native.saveastable (v1) [e6e4bf59-c328-4149-a4f8
-7833c3e6c1a0] =====*/
89 BEGIN

```

```

90 DECLARE __destination STRING DEFAULT 'carto-dw-ac-t872o53f.
    private_jorgekk22_3000e6c3.accidentalidad';
91 BEGIN
92 EXECUTE IMMEDIATE
93 REPLACE(
94     '''DROP TABLE IF EXISTS `####`'',
95     '####',
96     __destination
97 );
98 EXECUTE IMMEDIATE
99 REPLACE(
100     '''CREATE TABLE `####`
101     CLONE `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
        WORKFLOW_8cb51442ff57d51e_243221859e77d290_result`'',
102     '####',
103     __destination
104 );
105 END;
106 END;
107
108 /*===== SaveToBucketAndNotify (v2) [61c13242-1eab-413e-b8bf
    -1307f8621b40] =====*/
109 BEGIN
110
111     DECLARE emails STRING DEFAULT '''["jorgekk22@gmail.com"]''';
112     DECLARE export_id STRING DEFAULT GENERATE_UUID();
113     DECLARE bucket STRING DEFAULT 'carto-tnt-gcp-europe-west1-export-
        storage';
114     DECLARE response STRING;
115     DECLARE headers STRING DEFAULT '''
116     { "Authorization": "Bearer eyJhbGciOiJIUzI1NiJ9.
        eyJhIjoiaWYWNfdDg3Mm81M2YiLCJqdGkiOiI5YTg2Y2YzZSJ9.gYbW00R1rkzFjjIks-
        fyNMpqxFIX0d_7ze72QhXNScQ",
117         "Content-Type": "application/json"
118     }''';
119     DECLARE bucket_urls STRING;
120     DECLARE payload STRING;
121     EXECUTE IMMEDIATE FORMAT(''
122     EXPORT DATA -- carto-export-id: %s
123     OPTIONS (
124         uri = 'gs://%s/%s-*.csv.gz',
125         format = 'CSV',
126         overwrite = true,
127         compression = 'GZIP',
128         header = true,
129         field_delimiter = ','
130     )
131     AS (
132     SELECT * FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.
        accidentalidad`
133     )
134     ''',
135     export_id, bucket, export_id
136 );
137 SET bucket_urls = (
138     WITH export_result AS (
139     SELECT timeline[0].pending_units + timeline[0].completed_units

```

```

140 AS num_files
141 FROM `carto-dw-ac-t872o53f`.`region-EU`.INFORMATION_SCHEMA.
142 JOBS_BY_USER
143 WHERE creation_time > TIMESTAMP_ADD(CURRENT_TIMESTAMP(),
144 INTERVAL -1 HOUR)
145 AND statement_type = 'EXPORT_DATA'
146 AND query LIKE CONCAT('%', '-- carto-export-id: ', export_id,
147 '%')
148 LIMIT 1
149 )
150 SELECT ARRAY_TO_STRING(ARRAY(
151 SELECT CONCAT(
152 ' ',
153 'https://storage.googleapis.com/',
154 bucket,
155 '/',
156 export_id,
157 '-',
158 LPAD(CAST(i AS STRING), 12, '0'),
159 '.',
160 'csv',
161 '.gz',
162 ' ',
163 ) AS url
164 FROM export_result, UNNEST(GENERATE_ARRAY(0, num_files - 1)) AS
165 i
166 ORDER BY i), ', ')
167 );
168 SET payload = CONCAT(''
169 {
170 "method": "email",
171 "payload": {
172 "emails": '', emails, '',
173 "subject": "accidentalidad",
174 "body": "<br><ul>{% for bucketUrl in bucketUrls %}<li>{{
175 bucketUrl }}</li>{% endfor %}</ul>",
176 "replacements": {
177 "bucketUrls": [ '', bucket_urls, '' ]
178 }
179 }
180 }
181 '');
182 );
183 SET response = `carto-un-eu.carto.__REQUEST`(
184 'post', 'https://gcp-europe-west1.api.carto.com',
185 'v3/workflows/notify', payload, headers
186 );
187 END;
188
189 /*===== native.dropcolumn (v1) [f2d26391-f3c4-413d-ba89-8
190 c4c652023cd] =====*/
191 BEGIN
192 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
193 workflows_temp_jorgekk22_3000e6c3.
194 WORKFLOW_8cb51442ff57d51e_5ac1103717aceed3_result`;
195 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.

```



```

workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_8cb51442ff57d51e_5ac1103717aceed3_result`
188 OPTIONS (
189   expiration_timestamp = TIMESTAMP_ADD(
190     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
191   )
192 )
193 AS
194 SELECT * EXCEPT (tipo_vehiculo_clasificado, tipo_persona, rango_edad,
195   sexo, lesividad_clasificada, positiva_alcohol, positiva_droga)
196 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
197   WORKFLOW_8cb51442ff57d51e_243221859e77d290_result`;
198 /*===== native.removeduplicatedrows (v1) [edb63c9b-7c59-4de0
199   -bebe-b4cf11b7302f] =====*/
200 BEGIN
201 DECLARE alias_encoded STRING;
202 DECLARE alias_decoded STRING;
203 EXECUTE IMMEDIATE
204 '''
205   with __alias AS(
206     SELECT REPLACE(
207       CASE data_type WHEN 'GEOGRAPHY' THEN 'ST_ASBINARY(%s) AS %s' ELSE '%s
208       AS %s' END
209       , '%s', column_name) col_alias_encoded,
210     REPLACE(
211       CASE data_type WHEN 'GEOGRAPHY' THEN 'ST_GEOGFROMWKB(%s) AS %s' ELSE
212       '%s AS %s' END
213       , '%s', column_name) col_alias_decoded
214     FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3`.
215     INFORMATION_SCHEMA.COLUMNS
216     WHERE table_name = 'WORKFLOW_8cb51442ff57d51e_5ac1103717aceed3_result'
217   )
218   SELECT STRING_AGG(col_alias_encoded, ', '), STRING_AGG(col_alias_decoded,
219     ', ')
220   FROM __alias
221 '''
222 INTO alias_encoded, alias_decoded;
223 EXECUTE IMMEDIATE
224 REPLACE(
225   REPLACE(
226     '''DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
227     workflows_temp_jorgekk22_3000e6c3.
228     WORKFLOW_8cb51442ff57d51e_a9fb81e85d4158b3_result`''',
229     '%s1',
230     alias_decoded
231   ),
232   '%s2',
233   alias_encoded
234 );
235 EXECUTE IMMEDIATE
236 REPLACE(
237   REPLACE(
238     '''CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.

```

```

workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_8cb51442ff57d51e_a9fb81e85d4158b3_result`
234  OPTIONS (
235      expiration_timestamp = TIMESTAMP_ADD(
236          CURRENT_TIMESTAMP(), INTERVAL 30 DAY
237      )
238  )
239  AS
240      SELECT %s1
241      FROM (SELECT DISTINCT %s2 FROM `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_8cb51442ff57d51e_5ac1103717aceed3_result`)''',
242      '%s1',
243      alias_decoded
244  ),
245      '%s2',
246      alias_encoded
247  );
248  END;
249
250  /*===== native.saveastable (v1) [26a19292-8422-4aa3-b8a4-65
c17980032e] =====*/
251  BEGIN
252  DECLARE __destination STRING DEFAULT `carto-dw-ac-t872o53f.
private_jorgekk22_3000e6c3.accidentes`;
253  BEGIN
254  EXECUTE IMMEDIATE
255  REPLACE(
256      '''DROP TABLE IF EXISTS `####`''',
257      '####',
258      __destination
259  );
260  EXECUTE IMMEDIATE
261  REPLACE(
262      '''CREATE TABLE `####`
263      CLONE `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_8cb51442ff57d51e_a9fb81e85d4158b3_result`''',
264      '####',
265      __destination
266  );
267  END;
268  END;
269
270  /*===== native.sample (v1) [5eb7e347-2258-4de9-b574-
e38af9889272] =====*/
271  BEGIN
272  DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_8cb51442ff57d51e_36843e5e4ffedaf1_result`;
273  CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_8cb51442ff57d51e_36843e5e4ffedaf1_result`
274  OPTIONS (
275      expiration_timestamp = TIMESTAMP_ADD(
276          CURRENT_TIMESTAMP(), INTERVAL 30 DAY
277      )
278  )

```

```

279 AS
280 SELECT *
281 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_8cb51442ff57d51e_a9fb81e85d4158b3_result`
282 ORDER BY RAND()
283 LIMIT 1000;
284 END;
285
286 /*===== native.saveastable (v1) [539d66b4-84d5-414b-b2e3-6
      c9d08845f71] =====*/
287 BEGIN
288 DECLARE __destination STRING DEFAULT `carto-dw-ac-t872o53f.
      private_jorgekk22_3000e6c3.accidentes_sample`;
289 BEGIN
290 EXECUTE IMMEDIATE
291 REPLACE(
292   '''DROP TABLE IF EXISTS `####`'',
293   '####',
294   __destination
295 );
296 EXECUTE IMMEDIATE
297 REPLACE(
298   '''CREATE TABLE `####`
299   CLONE `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_8cb51442ff57d51e_36843e5e4ffedaf1_result`'',
300   '####',
301   __destination
302 );
303 END;
304 END;
305
306 /*===== native.join (v1.2) [381809b0-69c7-482d-a01c-64
      f7f29cae7c] =====*/
307 BEGIN
308 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
      workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_8cb51442ff57d51e_1215d2ec83f4eb00_result`;
309 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
      workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_8cb51442ff57d51e_1215d2ec83f4eb00_result`
310 OPTIONS (
311   expiration_timestamp = TIMESTAMP_ADD(
312     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
313 )
314 )
315 AS
316 SELECT
317   _main.*,
318   _joined.districto AS distrito_joined, _joined.geom AS geom_joined,
319   _joined.num_expediente AS num_expediente_joined, _joined.fecha AS
      fecha_joined, _joined.tipo_accidente_clasificado AS
      tipo_accidente_clasificado_joined, _joined.estado_meteorologico AS
      estado_meteorologico_joined, _joined.anno AS anno_joined, _joined.mes AS
      mes_joined, _joined.dia_mes AS dia_mes_joined, _joined.dia_semana AS
      dia_semana_joined, _joined.horas AS horas_joined, _joined.hora_rango AS
      hora_rango_joined
319 FROM

```

```

320     `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
        WORKFLOW_8cb51442ff57d51e_243221859e77d290_result` AS _main
321 INNER JOIN
322     `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
        WORKFLOW_8cb51442ff57d51e_36843e5e4ffedaf1_result` AS _joined
323 ON
324     _main.num_expediente = _joined.num_expediente;
325 END;
326
327 /*===== native.dropcolumn (v1) [dd23a5b7-1138-4894-bbae-
        fa4f874703a0] =====*/
328 BEGIN
329 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
        workflows_temp_jorgekk22_3000e6c3.
        WORKFLOW_8cb51442ff57d51e_07d11446c3ed09e5_result`;
330 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
        workflows_temp_jorgekk22_3000e6c3.
        WORKFLOW_8cb51442ff57d51e_07d11446c3ed09e5_result`
331 OPTIONS (
332     expiration_timestamp = TIMESTAMP_ADD(
333         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
334     )
335 )
336 AS
337 SELECT * EXCEPT (distrito_joined, geom_joined, num_expediente_joined,
        fecha_joined, tipo_accidente_clasificado_joined,
        estado_meteorologico_joined, anno_joined, mes_joined, dia_mes_joined,
        dia_semana_joined, horas_joined, hora_rango_joined)
338 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
        WORKFLOW_8cb51442ff57d51e_1215d2ec83f4eb00_result`;
339 END;
340
341 /*===== native.saveastable (v1) [1a484935-a01d-41fc
        -9303-56988528b6c2] =====*/
342 BEGIN
343 DECLARE __destination STRING DEFAULT `carto-dw-ac-t872o53f.
        private_jorgekk22_3000e6c3.accidentalidad_sample`;
344 BEGIN
345 EXECUTE IMMEDIATE
346 REPLACE(
347     '''DROP TABLE IF EXISTS `####`''',
348     '####',
349     __destination
350 );
351 EXECUTE IMMEDIATE
352 REPLACE(
353     '''CREATE TABLE `####`
354     CLONE `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
        WORKFLOW_8cb51442ff57d51e_07d11446c3ed09e5_result`''',
355     '####',
356     __destination
357 );
358 END;
359 END;

```

Listing A.2: SQL del workflow de accidentalidad.

Workflow de Voronoi

```

1  /*
2  Code generated by Carto Workflows Engine (RUN)
3  - workflowid:2202f4ba-bee1-4ed2-8897-8a10c4321a1a
4  - versionid:0de029df103a99bf
5  - paramsid:97d170e1550eee4a
6  */
7
8  /*===== native.customsql (v2.0.0) [2c2accaa-ca7a-4149-acce
   -56e8485ccb25] =====*/
9  BEGIN
10 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_b4e0f7e821e5c553_e6e2dfef8ede4136_result`
11 OPTIONS (
12   expiration_timestamp = TIMESTAMP_ADD(
13     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
14   )
15 )
16 AS
17 SELECT
18   ST_Union(ARRAY_AGG(geom)) AS distritos_union
19 FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.distritos`;
20 END;
21
22 /*===== native.customsql (v2.0.0) [bc587317-0b2a-47e8-8e59-0
   b11dbd2aee6] =====*/
23 BEGIN
24 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_b4e0f7e821e5c553_1c56880096e47d73_result`
25 OPTIONS (
26   expiration_timestamp = TIMESTAMP_ADD(
27     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
28   )
29 )
30 AS
31
32
33
34
35 WITH
36   _hospital_data_for_join AS (
37     SELECT
38       nombre,
39       geom AS hospital_geom_for_join
40     FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.hospitales`
41   ),
42   _hospital_points_array AS (
43     SELECT ARRAY_AGG(geom) AS points_array
44     FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.hospitales`
45   ),
46   _madrid_boundary_polygon_cte AS (
47     SELECT distritos_union AS boundary_poly
48     FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_b4e0f7e821e5c553_e6e2dfef8ede4136_result`

```

```

49         LIMIT 1
50     ),
51     _madrid_bbox_struct AS (
52         SELECT ST_BOUNDINGBOX(boundary_poly) AS bbox_struct
53         FROM _madrid_boundary_polygon_cte
54     ),
55     _madrid_boundary_bbox_coords AS (
56         SELECT
57             [
58                 bbox_struct.xmin,
59                 bbox_struct.ymin,
60                 bbox_struct.xmax,
61                 bbox_struct.ymax
62             ] AS bbox_array
63         FROM _madrid_bbox_struct
64     ),
65     _voronoi_tessellation_geoms AS (
66         SELECT
67             voronoi_cell AS voronoi_geom_raw
68         FROM
69             ( SELECT
70                 `carto-un-eu.carto`.ST_VORONOIPOLYGONS(
71                     (SELECT points_array FROM _hospital_points_array),
72                     (SELECT bbox_array FROM _madrid_boundary_bbox_coords)
73                 ) AS voronoi_collection
74             ),
75             UNNEST(voronoi_collection) AS voronoi_cell
76     )
77
78 SELECT
79     h_join.nombre,
80     vg.voronoi_geom_raw AS voronoi_geom_extendido
81 FROM
82     _voronoi_tessellation_geoms vg
83 JOIN
84     _hospital_data_for_join h_join ON ST_CONTAINS(vg.voronoi_geom_raw,
85     h_join.hospital_geom_for_join);
86
87 /*===== native.intersection (v1) [595678c5-6ddb-41d4-a987-7
88     ea19f6cdb6d] =====*/
89 BEGIN
90 DECLARE alias STRING;
91 EXECUTE IMMEDIATE
92 '''
93     with __alias AS(
94         SELECT CONCAT(
95             'b.', column_name, ' AS ', column_name, '_secondary'
96         ) col_alias
97         FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3`.
98         INFORMATION_SCHEMA.COLUMNS
99         WHERE table_name = 'WORKFLOW_b4e0f7e821e5c553_e6e2dfef8ede4136_result'
100     )
101     SELECT STRING_AGG(col_alias, ', ')
102     FROM __alias
103 '''

```

```

103 INTO alias;
104
105 EXECUTE IMMEDIATE
106 REPLACE(
107 '''CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
    workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_b4e0f7e821e5c553_286404bc423cc563_result`
108 OPTIONS (
109     expiration_timestamp = TIMESTAMP_ADD(
110         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
111     )
112 )
113 AS
114 SELECT
115     ST_INTERSECTION(
116         b.districts_union,
117         a.voronoi_geom_extendido
118     )
119     AS intersection_voronoi_geom_extendido_districts_union,
120     a.*, %s
121 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_b4e0f7e821e5c553_1c56880096e47d73_result` AS a
122 JOIN `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_b4e0f7e821e5c553_e6e2dfef8ede4136_result` AS b
123 ON ST_INTERSECTS(
124     b.districts_union,
125     a.voronoi_geom_extendido
126 )''' ,
127 '%s' ,
128 alias
129 );
130 END;
131
132 /*===== native.dropcolumn (v1) [d07d77d1-28e7-48d8-baf0-4837
    ff2e02a3] =====*/
133 BEGIN
134 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
    workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_b4e0f7e821e5c553_630db1ab369e167a_result`
135 OPTIONS (
136     expiration_timestamp = TIMESTAMP_ADD(
137         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
138     )
139 )
140 AS
141 SELECT * EXCEPT (voronoi_geom_extendido, districts_union_secondary)
142 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_b4e0f7e821e5c553_286404bc423cc563_result`;
143 END;
144
145 /*===== native.renamecolumn (v1) [ba7c3b87-aec8-4857-bf17-
    ffe6b325fd37] =====*/
146 BEGIN
147 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
    workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_b4e0f7e821e5c553_478a3f591e217766_result`
148 OPTIONS (

```



```
149 expiration_timestamp = TIMESTAMP_ADD(
150     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
151 )
152 )
153 AS
154 SELECT * EXCEPT (intersection_voronoi_geom_extendido_distritos_union),
155     intersection_voronoi_geom_extendido_distritos_union AS
156     voronoi_distritos_cell
157 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
158     WORKFLOW_b4e0f7e821e5c553_630db1ab369e167a_result`;
159 END;
160
161 /*===== native.saveastable (v1) [6689b5b2-4c83-47d6-93c9-968
162     dbfffc337] =====*/
163 BEGIN
164 DECLARE __destination STRING DEFAULT 'carto-dw-ac-t872o53f.
165     private_jorgekk22_3000e6c3.voronoi';
166 BEGIN
167 EXECUTE IMMEDIATE
168 REPLACE(
169     '''DROP TABLE IF EXISTS `####`'',
170     '####',
171     __destination
172 );
173 EXECUTE IMMEDIATE
174 REPLACE(
175     '''CREATE TABLE IF NOT EXISTS `####`
176     CLONE `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
177     WORKFLOW_b4e0f7e821e5c553_478a3f591e217766_result`'',
178     '####',
179     __destination
180 );
181 END;
182 END;
183
184 /*===== native.saveastable (v1) [788b8704-bf5c-48fa-87d4-7
185     db50f28ffa0] =====*/
186 BEGIN
187 DECLARE __destination STRING DEFAULT 'carto-dw-ac-t872o53f.
188     private_jorgekk22_3000e6c3.distritos_union';
189 BEGIN
190 EXECUTE IMMEDIATE
191 REPLACE(
192     '''DROP TABLE IF EXISTS `####`'',
193     '####',
194     __destination
195 );
196 EXECUTE IMMEDIATE
197 REPLACE(
198     '''CREATE TABLE IF NOT EXISTS `####`
199     CLONE `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
200     WORKFLOW_b4e0f7e821e5c553_e6e2dfef8ede4136_result`'',
201     '####',
202     __destination
203 );
204 END;
```

197 **END;**

Listing A.3: SQL del workflow de Voronoi.

Workflow de Comparación de Isolíneas

```

1  /*
2  Code generated by Carto Workflows Engine (RUN)
3  - workflowid:ad46aa14-82db-47f1-a395-517edadba387
4  - versionid:a187e977d9eff8fe
5  - paramsid:97d170e1550eee4a
6  */
7
8  /*===== native.wheresimplified (v1) [4a70cbb3-0bbd-4d70-9cca
   -b1df5a34ab39] =====*/
9  BEGIN
10 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_3d9ac53530e93e18_8ea63dfdd84f3ac8_match`;
11 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_3d9ac53530e93e18_8ea63dfdd84f3ac8_match`
12 OPTIONS (
13   expiration_timestamp = TIMESTAMP_ADD(
14     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
15   )
16 )
17 AS
18 SELECT *
19 FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.hospitales`
20 WHERE
21   nombre = 'Hospital Universitario la Paz';
22
23 END;
24
25 /*===== native.isolines (v2) [89cddc6f-9708-4708-b05f-
   ddffb30d5291] =====*/
26 BEGIN
27 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_3d9ac53530e93e18_4771a1188c0d06a8_result`;
28 BEGIN
29
30 CALL `carto-un-eu.carto`.CREATE_ISOLINES(
31   'https://gcp-europe-west1.api.carto.com',
32   'eyJhbGciOiJIUzI1NiJ9.eyJhIjojYW50dG83Mm81M2YiLCJqdGkiOiI2NDY2ZDg4MyJ9.
   YJG_H6JsBlqZuWeqAd_QCxCjTSElcV3_DAKjF5gaaQ',
33   'SELECT * FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_3d9ac53530e93e18_8ea63dfdd84f3ac8_match`',
34   'carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_3d9ac53530e93e18_4771a1188c0d06a8_result',
35   'geom',
36   'car',
37   2500,
38   'distance',
39   '{"polygons_filter":{"limit":1},"carto_keep_orig_geom":true}');
40
41 END;
42 END;
43
44 /*===== native.isolines (v2) [a40160e9-4940-4a76-a52e-25079

```

```

b168317] =====*/
45 BEGIN
46 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
    workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_3d9ac53530e93e18_ad5990499318251c_result`;
47 BEGIN
48
49 CALL `carto-un-eu.carto`.CREATE_ISOLINES(
50     'https://gcp-europe-west1.api.carto.com',
51     'eyJhbGciOiJIUzI1NiJ9.eyJhIjoiYWNfdG93Mm81M2YiLCJqdGkiOiI2NDY2ZDg4MyJ9.
    YJG_H6JsBlqZuWeqAd_QCxCNcjTSElcV3_DAKjF5gaaQ',
52     'SELECT * FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_3d9ac53530e93e18_8ea63dfdd84f3ac8_match`',
53     'carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_3d9ac53530e93e18_ad5990499318251c_result',
54     'geom',
55     'car',
56     600,
57     'time',
58     '{"polygons_filter":{"limit":1},"carto_keep_orig_geom":true}');
59
60 END;
61 END;
62
63 /*===== native.join (v1.2) [b0a8d34e-3a0b-41b6-b147-9461
    f5a40f6e] =====*/
64 BEGIN
65 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
    workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_3d9ac53530e93e18_6fd5191c3a055a70_result`;
66 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
    workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_3d9ac53530e93e18_6fd5191c3a055a70_result`
67 OPTIONS (
68     expiration_timestamp = TIMESTAMP_ADD(
69         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
70     )
71 )
72 AS
73 SELECT
74     _main.*,
75     _joined.geom AS geom_joined, _joined.carto_isoline_metadata AS
    carto_isoline_metadata_joined, _joined.nombre AS nombre_joined
76 FROM
77     `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_3d9ac53530e93e18_ad5990499318251c_result` AS _main
78 INNER JOIN
79     `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_3d9ac53530e93e18_4771a1188c0d06a8_result` AS _joined
80 ON
81     _main.nombre = _joined.nombre;
82 END;
83
84 /*===== native.dropcolumn (v1) [0fea438f-d045-4dd8-bfcd-3
    e4ad81b5e89] =====*/
85 BEGIN
86 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.

```

```

workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_3d9ac53530e93e18_ae070c3e9223587f_result`;
87 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_3d9ac53530e93e18_ae070c3e9223587f_result`
88 OPTIONS (
89   expiration_timestamp = TIMESTAMP_ADD(
90     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
91   )
92 )
93 AS
94 SELECT * EXCEPT (nombre_joined, carto_isoline_metadata_joined,
95   carto_isoline_metadata)
96 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
97   WORKFLOW_3d9ac53530e93e18_6fd5191c3a055a70_result`;
98 END;
99
100 /*===== native.renamecolumn (v1) [e6bdc840-ad30-4f33-8828-
101   f3eaab5ff498] =====*/
102 BEGIN
103 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
104   workflows_temp_jorgekk22_3000e6c3.
105   WORKFLOW_3d9ac53530e93e18_89dc5930ef434a65_result`;
106 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
107   workflows_temp_jorgekk22_3000e6c3.
108   WORKFLOW_3d9ac53530e93e18_89dc5930ef434a65_result`
109 OPTIONS (
110   expiration_timestamp = TIMESTAMP_ADD(
111     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
112   )
113 )
114 AS
115 SELECT * EXCEPT (geom),
116   geom AS isocrona
117 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
118   WORKFLOW_3d9ac53530e93e18_ae070c3e9223587f_result`;
119 END;
120
121 /*===== native.renamecolumn (v1) [3c66a1ac-1a80-4b73-adea-9
122   e5e342b35bf] =====*/
123 BEGIN
124 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
125   workflows_temp_jorgekk22_3000e6c3.
126   WORKFLOW_3d9ac53530e93e18_e61f45a112f76cd8_result`;
127 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
128   workflows_temp_jorgekk22_3000e6c3.
129   WORKFLOW_3d9ac53530e93e18_e61f45a112f76cd8_result`
130 OPTIONS (
131   expiration_timestamp = TIMESTAMP_ADD(
132     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
133   )
134 )
135 AS
136 SELECT * EXCEPT (geom_joined),
137   geom_joined AS isodistancia
138 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
139   WORKFLOW_3d9ac53530e93e18_89dc5930ef434a65_result`;

```

```
126 END;
127
128 /*===== native.saveastable (v1) [1e80067d-4ee3-4ef7-83d2-8
129 e87f7f500a4] =====*/
129 BEGIN
130 DECLARE __destination STRING DEFAULT 'carto-dw-ac-t872o53f.
131 private_jorgekk22_3000e6c3.hospital_isocrona_isodistancia';
131 BEGIN
132 EXECUTE IMMEDIATE
133 REPLACE(
134 '''DROP TABLE IF EXISTS `####`'',
135 '####',
136 __destination
137 );
138 EXECUTE IMMEDIATE
139 REPLACE(
140 '''CREATE TABLE `####`
141 CLONE `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
142 WORKFLOW_3d9ac53530e93e18_e61f45a112f76cd8_result`'',
143 '####',
144 __destination
145 );
145 END;
146 END;
```

Listing A.4: SQL del workflow de comparación Isócrona vs. Isodistancia.

Workflow de Perfil de Riesgo de Hospitales

```

1  /*
2  Code generated by Carto Workflows Engine (RUN)
3  - workflowid:8f4e78d8-21c0-435b-bcc6-a50fd389c306
4  - versionid:3b1d3f0cff97501c
5  - paramsid:97d170e1550eee4a
6  */
7
8  /*===== native.h3frompoint (v1) [3bafd4d7-4b3f-4352-a3eb-
   b31e02b9dc96] =====*/
9  BEGIN
10 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
    workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_6013105ac19a5b7f_f107384622ee8b2c_result`
11 OPTIONS (
12   expiration_timestamp = TIMESTAMP_ADD(
13     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
14   )
15 )
16 AS
17 SELECT
18   `carto-un-eu.carto`.H3_FROMGEOPOINT(
19     geom, 9
20   ) h3, *
21 FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.accidentes`;
22 END;
23
24 /*===== native.isolines (v2) [ed10fa53-a7af-48eb-a3fd-
   f198fbeac3ab] =====*/
25 BEGIN
26 BEGIN
27 DECLARE tablesCount INT64;
28 DECLARE tableNames ARRAY<STRING> DEFAULT ['\'
    WORKFLOW_6013105ac19a5b7f_6ef992b50024d076_result\''];
29 EXECUTE IMMEDIATE '''
30   SELECT COUNT(1) AS cnt
31   FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
   __TABLES_SUMMARY__`
32   WHERE table_id IN (''' || ARRAY_TO_STRING(tableNames, ', ') || ''')
33   ''' INTO tablesCount;
34 IF tablesCount < 1 THEN
35   BEGIN
36
37     CALL `carto-un-eu.carto`.CREATE_ISOLINES(
38       'https://gcp-europe-west1.api.carto.com',
39       'eyJhbGciOiJIUzI1NiJ9.
   eyJhIjoieWNfdGg3Mm81M2YiLCJqdGkiOiI0YWI1NjU2MyJ9.4
   FGgabe5KvSsDwNc2FbUQv13eGFrFN3w828VXH1BT0s',
40       'SELECT * FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.
   hospitales`',
41       'carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_6013105ac19a5b7f_6ef992b50024d076_result',
42       'geom',
43       'car',
44       600,
45       'time',

```



```

46         '{"polygons_filter":{"limit":1},"carto_keep_orig_geom":true}');
47
48     END;
49 END IF;
50 END;
51 END;
52
53 /*===== native.h3polyfill (v1) [205c15d7-9444-40f2-a7dd-78
54     ffaa853c29] =====*/
55 BEGIN
56 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
57     workflows_temp_jorgekk22_3000e6c3.
58     WORKFLOW_6013105ac19a5b7f_39c4ad73aac220bf_result`
59 OPTIONS (
60     expiration_timestamp = TIMESTAMP_ADD(
61         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
62     )
63 )
64 AS
65 WITH __h3 AS
66 (
67     SELECT
68         s.carto_isoline_metadata, s.nombre,
69         `carto-un-eu.carto`.H3_POLYFILL_MODE(
70             geom,
71             9,
72             'center'
73         ) h3s
74 FROM
75     (
76         SELECT *
77         FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
78             WORKFLOW_6013105ac19a5b7f_6ef992b50024d076_result`
79         WHERE geom IS NOT NULL
80     ) s
81 )
82 SELECT * EXCEPT(h3s)
83 FROM __h3, __h3.h3s AS h3;
84 END;
85
86 /*===== native.isolines (v2) [ce935e0b-178d-4399-82f7-05
87     e561ad5ab7] =====*/
88 BEGIN
89 BEGIN
90 DECLARE tablesCount INT64;
91 DECLARE tableNames ARRAY<STRING> DEFAULT ['\'
92     WORKFLOW_6013105ac19a5b7f_d8a8ce1bc8ebe972_result\''
93 ];
94 EXECUTE IMMEDIATE '''
95     SELECT COUNT(1) AS cnt
96     FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
97     __TABLES_SUMMARY__`
98     WHERE table_id IN (''' || ARRAY_TO_STRING(tableNames, ', ') || ''')
99     ''' INTO tablesCount;
100 IF tablesCount < 1 THEN
101 BEGIN
102     CALL `carto-un-eu.carto`.CREATE_ISOLINES(

```

```

96         'https://gcp-europe-west1.api.carto.com',
97         'eyJhbGciOiJIUzI1NiJ9.
eyJhIjoIYWNfdDg3Mm81M2YiLCJqdGkiOiI0YWI1NjU2MyJ9.4
FGgabe5KvSsDwNc2FbUQv13eGFrFN3w828VXH1BT0s',
98         'SELECT * FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.
hospitales`',
99         'carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_6013105ac19a5b7f_d8a8ce1bc8ebe972_result',
100         'geom',
101         'car',
102         900,
103         'time',
104         '{"polygons_filter":{"limit":1},"carto_keep_orig_geom":true}');
105
106     END;
107 END IF;
108 END;
109 END;
110
111 /*===== native.h3polyfill (v1) [4e789487-574a-4bb7-bea7-
aace941b1364] =====*/
112 BEGIN
113 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_6013105ac19a5b7f_fb7705bc12e217ad_result`
114 OPTIONS (
115     expiration_timestamp = TIMESTAMP_ADD(
116         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
117     )
118 )
119 AS
120 WITH __h3 AS
121 (
122     SELECT
123         s.carto_isoline_metadata, s.nombre,
124         `carto-un-eu.carto`.H3_POLYFILL_MODE(
125             geom,
126             9,
127             'center'
128         ) h3s
129 FROM
130     (
131         SELECT *
132         FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_6013105ac19a5b7f_d8a8ce1bc8ebe972_result`
133         WHERE geom IS NOT NULL
134     ) s
135 )
136 SELECT * EXCEPT(h3s)
137 FROM __h3, __h3.h3s AS h3;
138 END;
139
140 /*===== native.isolines (v2) [b68f7cf1-ae99-4782-8f41-
be2aee72b337] =====*/
141 BEGIN
142 BEGIN
143     DECLARE tablesCount INT64;

```

```

144 DECLARE tableNames ARRAY<STRING> DEFAULT ['\
    WORKFLOW_6013105ac19a5b7f_933ce9f10a6c1043_result\'];
145 EXECUTE IMMEDIATE '''
146     SELECT COUNT(1) AS cnt
147     FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
    __TABLES_SUMMARY__`
148     WHERE table_id IN (''' || ARRAY_TO_STRING(tableNames, ', ') || '')
149 ''' INTO tablesCount;
150 IF tablesCount < 1 THEN
151     BEGIN
152
153         CALL `carto-un-eu.carto`.CREATE_ISOLINES(
154             'https://gcp-europe-west1.api.carto.com',
155             'eyJhbGciOiJIUzI1NiJ9.
            eyJhIjoiyWNfdDg3Mm81M2YiLCJqdGkiOiI0YWI1NjU2MyJ9.4
            FGgabe5KvSsDwNc2FbUQv13eGFrFN3w828VXH1BT0s',
156             'SELECT * FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.
            hospitales`',
157             'carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
            WORKFLOW_6013105ac19a5b7f_933ce9f10a6c1043_result',
158             'geom',
159             'car',
160             1800,
161             'time',
162             '{"polygons_filter":{"limit":1},"carto_keep_orig_geom":true}');
163
164     END;
165 END IF;
166 END;
167 END;
168
169 /*===== native.h3polyfill (v1) [cffbea23-f119-4ec0-be9d-588
    fc34f2298] =====*/
170 BEGIN
171 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
    workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_6013105ac19a5b7f_31ab0974b5839c55_result`
172 OPTIONS (
173     expiration_timestamp = TIMESTAMP_ADD(
174         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
175     )
176 )
177 AS
178 WITH __h3 AS
179 (
180     SELECT
181         s.carto_isoline_metadata, s.nombre,
182         `carto-un-eu.carto`.H3_POLYFILL_MODE(
183             geom,
184             9,
185             'center'
186         ) h3s
187 FROM
188     (
189         SELECT *
190         FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
            WORKFLOW_6013105ac19a5b7f_933ce9f10a6c1043_result`

```

```

191     WHERE geom IS NOT NULL
192   ) s
193 )
194 SELECT * EXCEPT(h3s)
195 FROM __h3, __h3.h3s AS h3;
196 END;
197
198 /*===== native.isolines (v2) [cfa2a0b8-e5a4-46c5-8a6c-
199   c31e637894db] =====*/
200 BEGIN
201 DECLARE tablesCount INT64;
202 DECLARE tableNames ARRAY<STRING> DEFAULT ['\
203   WORKFLOW_6013105ac19a5b7f_e778c2b05f829258_result\'];
204 EXECUTE IMMEDIATE '''
205   SELECT COUNT(1) AS cnt
206   FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
207   __TABLES_SUMMARY__`
208   WHERE table_id IN (''' || ARRAY_TO_STRING(tableNames, ', ') || ''')
209   ''' INTO tablesCount;
210 IF tablesCount < 1 THEN
211   BEGIN
212     CALL `carto-un-eu.carto`.CREATE_ISOLINES(
213       'https://gcp-europe-west1.api.carto.com',
214       'eyJhbGciOiJIUzI1NiJ9.
215       eyJhIjoiyWNfdGg3Mm81M2YiLCJqdGkiOiI0YWI1NjU2MyJ9.4
216       FGgabe5KvSsDwNc2FbUQv13eGFrFN3w828VXH1BT0s',
217       'SELECT * FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.
218       hospitales`',
219       'carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
220       WORKFLOW_6013105ac19a5b7f_e778c2b05f829258_result',
221       'geom',
222       'car',
223       2700,
224       'time',
225       '{"polygons_filter":{"limit":1},"carto_keep_orig_geom":true}');
226   END;
227 END IF;
228 END;
229 END;
230
231 /*===== native.h3polyfill (v1) [004e4be6-fbe3-4450-9f64-4
232   a2d89c0d8bc] =====*/
233 BEGIN
234 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
235   workflows_temp_jorgekk22_3000e6c3.
236   WORKFLOW_6013105ac19a5b7f_9330f325fd147eeb_result`
237 OPTIONS (
238   expiration_timestamp = TIMESTAMP_ADD(
239     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
240   )
241 )
242 AS
243 WITH __h3 AS
244 (

```

```

238 SELECT
239     s.carto_isoline_metadata, s.nombre,
240     `carto-un-eu.carto`.H3_POLYFILL_MODE(
241         geom,
242         9,
243         'center'
244     ) h3s
245 FROM
246     (
247         SELECT *
248         FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
249             WORKFLOW_6013105ac19a5b7f_e778c2b05f829258_result`
250         WHERE geom IS NOT NULL
251     ) s
252 SELECT * EXCEPT(h3s)
253 FROM __h3, __h3.h3s AS h3;
254 END;
255
256 /*===== native.isolines (v2) [32885080-3ff4-4aaa-8897-
257     b042c3f300f0] =====*/
258 BEGIN
259 DECLARE tablesCount INT64;
260 DECLARE tableNames ARRAY<STRING> DEFAULT ['\`
261     WORKFLOW_6013105ac19a5b7f_fceaa5976fa1c6bc_result\`'];
262 EXECUTE IMMEDIATE '''
263     SELECT COUNT(1) AS cnt
264     FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
265     __TABLES_SUMMARY__`
266     WHERE table_id IN (''' || ARRAY_TO_STRING(tableNames, ', ') || ''')
267     ''' INTO tablesCount;
268 IF tablesCount < 1 THEN
269     BEGIN
270         CALL `carto-un-eu.carto`.CREATE_ISOLINES(
271             'https://gcp-europe-west1.api.carto.com',
272             'eyJhbGciOiJIUzI1NiJ9.
273             eyJhIjoieWNfdGg3Mm81M2YiLCJqdGkiOiI0YWI1NjU2MyJ9.4
274             FGgabc5KvSsDwNc2FbUQv13eGFrfFN3w828VXH1BT0s',
275             'SELECT * FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.
276             hospitales`',
277             'carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
278             WORKFLOW_6013105ac19a5b7f_fceaa5976fa1c6bc_result',
279             'geom',
280             'car',
281             300,
282             'time',
283             '{"polygons_filter":{"limit":1},"carto_keep_orig_geom":true}');
284     END;
285 END IF;
286 END;
287 END;
288
289 /*===== native.customsql (v2.0.0) [24c20f78-8a0f-4adf-bc34
290     -847268a696d0] =====*/

```

```

286 BEGIN
287 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
      workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_6013105ac19a5b7f_78cbfba00c14a127_result`
288 OPTIONS (
289   expiration_timestamp = TIMESTAMP_ADD(
290     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
291   )
292 )
293 AS
294
295 SELECT
296   *
297 FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.accidentes`
298 WHERE num_expediente IN (
299   SELECT DISTINCT num_expediente
300   FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.accidentalidad`
301   WHERE lesividad_clasificada IN ('HERIDOS GRAVES', 'FALLECIDOS')
302 );
303 END;
304
305 /*===== native.saveastable (v1) [88854892-6b3f-4e26-bdd9
      -3539f7f267d2] =====*/
306 BEGIN
307 DECLARE __destination STRING DEFAULT `carto-dw-ac-t872o53f.
      private_jorgekk22_3000e6c3.accidentes_graves`;
308 BEGIN
309 EXECUTE IMMEDIATE
310 REPLACE(
311   '''DROP TABLE IF EXISTS `####`'',
312   '####',
313   __destination
314 );
315 EXECUTE IMMEDIATE
316 REPLACE(
317   '''CREATE TABLE IF NOT EXISTS `####`
318   CLONE `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
319   WORKFLOW_6013105ac19a5b7f_78cbfba00c14a127_result`'',
320   '####',
321   __destination
322 );
323 END;
324
325 /*===== native.h3polyfill (v1) [ccd37cd6-df63-4260-adcc-
      a946446f1c2c] =====*/
326 BEGIN
327 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
      workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_6013105ac19a5b7f_e5780b987f14b0c6_result`
328 OPTIONS (
329   expiration_timestamp = TIMESTAMP_ADD(
330     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
331   )
332 )
333 AS
334 WITH __h3 AS

```

```

335 (
336     SELECT
337         s.carto_isoline_metadata, s.nombre,
338         `carto-un-eu.carto`.H3_POLYFILL_MODE(
339             geom,
340             9,
341             'center'
342         ) h3s
343     FROM
344         (
345             SELECT *
346             FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
347             WORKFLOW_6013105ac19a5b7f_fceaa5976fa1c6bc_result`
348             WHERE geom IS NOT NULL
349         ) s
350     SELECT * EXCEPT(h3s)
351     FROM __h3, __h3.h3s AS h3;
352 END;
353
354 /*===== native.h3frompoint (v1) [d6d75860-f169-43c9-9d09
355 -27048dad5821] =====*/
356 BEGIN
357 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
358     workflows_temp_jorgekk22_3000e6c3.
359     WORKFLOW_6013105ac19a5b7f_ae4ed3c75235b667_result`
360 OPTIONS (
361     expiration_timestamp = TIMESTAMP_ADD(
362         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
363     )
364 )
365 AS
366 SELECT
367     `carto-un-eu.carto`.H3_FROMGEOGPOINT(
368         geom, 9
369     ) h3, *
370 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
371 WORKFLOW_6013105ac19a5b7f_78cbfba00c14a127_result`;
372 END;
373
374 /*===== native.customsql (v2.0.0) [878ac897-6a31-498e-9e5b-
375 ac8bcdaa02c0] =====*/
376 BEGIN
377 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
378     workflows_temp_jorgekk22_3000e6c3.
379     WORKFLOW_6013105ac19a5b7f_21d2feaa8ef05412_result`
380 OPTIONS (
381     expiration_timestamp = TIMESTAMP_ADD(
382         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
383     )
384 )
385 AS
386 WITH all_h3_times AS (
387     SELECT h3, 300 as time FROM carto-dw-ac-t872o53f.
388     workflows_temp_jorgekk22_3000e6c3.
389     WORKFLOW_6013105ac19a5b7f_e5780b987f14b0c6_result

```

```

382     UNION ALL
383     SELECT h3, 600 as time FROM carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_6013105ac19a5b7f_39c4ad73aac220bf_result
384     UNION ALL
385     SELECT h3, 900 as time FROM carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_6013105ac19a5b7f_fb7705bc12e217ad_result
386
387 ),
388
389 min_time_per_h3 AS (
390     SELECT h3, MIN(time) as min_time
391     FROM all_h3_times
392     GROUP BY h3
393 )
394
395 SELECT
396     h3,
397     CASE
398         WHEN min_time = 300 THEN '00-05 min'
399         WHEN min_time = 600 THEN '05-10 min'
400         WHEN min_time = 900 THEN '10-15 min'
401
402     END as catchment_zone
403 FROM min_time_per_h3;
404 END;
405
406 /*===== native.customsql (v2.0.0) [a2180ac3-b800-4452-9900-
ecc5ded1656b] =====*/
407 BEGIN
408 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_6013105ac19a5b7f_7dd4e5ceb1facac3_result`
409 OPTIONS (
410     expiration_timestamp = TIMESTAMP_ADD(
411         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
412     )
413 )
414 AS
415 SELECT h3, catchment_zone FROM `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_6013105ac19a5b7f_21d2feaa8ef05412_result`
416 UNION ALL
417
418 SELECT h3, '15-30 min' as catchment_zone
419 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_6013105ac19a5b7f_31ab0974b5839c55_result`
420 WHERE h3 NOT IN (SELECT h3 FROM `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_6013105ac19a5b7f_21d2feaa8ef05412_result`)
421 UNION ALL
422
423 SELECT h3, '30-45 min' as catchment_zone
424 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_6013105ac19a5b7f_9330f325fd147eeb_result`
425

```



```

426 WHERE h3 NOT IN (SELECT h3 FROM `carto-dw-ac-t872o53f.
    workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_6013105ac19a5b7f_31ab0974b5839c55_result`);
427 END;
428
429 /*===== native.customsql (v2.0.0) [db7d52bb-1647-4c31-ab47-7
    d90d77c5667] =====*/
430 BEGIN
431 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
    workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_6013105ac19a5b7f_31e65d4fca4a51d5_result`
432 OPTIONS (
433     expiration_timestamp = TIMESTAMP_ADD(
434         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
435     )
436 )
437 AS
438 WITH accidentes_simplificados AS (
439     SELECT h3, num_expediente, tipo_accidente_clasificado FROM `carto-dw-
    ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_6013105ac19a5b7f_f107384622ee8b2c_result`
440 ),
441 graves_simplificados AS (
442     SELECT h3, num_expediente FROM `carto-dw-ac-t872o53f.
    workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_6013105ac19a5b7f_ae4ed3c75235b667_result`
443 )
444
445 SELECT
446     a.h3,
447     a.catchment_zone,
448
449     COALESCE(COUNT(DISTINCT s.num_expediente), 0) as
    volumen_total_accidentes,
450     COALESCE(COUNT(DISTINCT g.num_expediente), 0) as severidad_alta,
451     COALESCE(COUNT(DISTINCT CASE WHEN s.tipo_accidente_clasificado = '
    Atropello a persona' THEN s.num_expediente END), 0) as riesgo_peatonal
452
453 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_6013105ac19a5b7f_7dd4e5ceb1facac3_result` a
454 LEFT JOIN accidentes_simplificados s ON a.h3 = s.h3
455 LEFT JOIN graves_simplificados g ON a.h3 = g.h3
456 GROUP BY
457     a.h3, a.catchment_zone;
458 END;
459
460 /*===== native.h3boundary (v1) [a911c403-f049-40a9-a734-8
    dc8827ea6af] =====*/
461 BEGIN
462 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
    workflows_temp_jorgekk22_3000e6c3.
    WORKFLOW_6013105ac19a5b7f_3d3e59ba219f4a8f_result`
463 OPTIONS (
464     expiration_timestamp = TIMESTAMP_ADD(
465         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
466     )
467 )

```

```

468 AS
469 SELECT
470     `carto-un-eu.carto`.H3_BOUNDARY(
471         h3
472     ) h3_geo, *
473 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
474     WORKFLOW_6013105ac19a5b7f_31e65d4fca4a51d5_result`;
475
476 /*===== native.customsql (v2.0.0) [2ed0caa1-0b01-426c-a624-
477     a1bb62ea004f] =====*/
478 BEGIN
479 CREATE TABLE IF NOT EXISTS `carto-dw-ac-t872o53f.
480     workflows_temp_jorgekk22_3000e6c3.
481     WORKFLOW_6013105ac19a5b7f_1409a9083dc47efd_result`
482 OPTIONS (
483     expiration_timestamp = TIMESTAMP_ADD(
484         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
485     )
486 )
487 AS
488 WITH madrid_boundary AS (
489     SELECT distritos_union AS boundary_geom FROM `carto-dw-ac-t872o53f.
490     private_jorgekk22_3000e6c3.distritos_union` LIMIT 1
491 )
492 SELECT
493     a.* EXCEPT(h3_geo),
494     ST_INTERSECTION(a.h3_geo, b.boundary_geom) as geometry
495 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
496     WORKFLOW_6013105ac19a5b7f_3d3e59ba219f4a8f_result` a, madrid_boundary b
497 WHERE ST_INTERSECTS(a.h3_geo, b.boundary_geom);
498
499 END;
500
501 /*===== native.saveastable (v1) [1ab1f4e0-5c56-4a2e-a6a7-
502     a1d7ca17bb69] =====*/
503 BEGIN
504 DECLARE __destination STRING DEFAULT `carto-dw-ac-t872o53f.
505     private_jorgekk22_3000e6c3.perfil_riesgo_hospitales_madrid_por_hexagono`
506 ;
507 BEGIN
508 EXECUTE IMMEDIATE
509 REPLACE(
510     '''DROP TABLE IF EXISTS `####`'',
511     '####',
512     __destination
513 );
514 EXECUTE IMMEDIATE
515 REPLACE(
516     '''CREATE TABLE IF NOT EXISTS `####`
517     CLONE `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
518     WORKFLOW_6013105ac19a5b7f_1409a9083dc47efd_result`'',
519     '####',
520     __destination
521 );
522 END;

```

513 **END ;**

Listing A.5: SQL del workflow de perfil de riesgo de hospitales.

Workflow de Análisis de Autocorrelación Espacial (LISA)

```

1  /*
2  Code generated by Carto Workflows Engine (RUN)
3  - workflowid:2617c781-ee0e-4d7a-b649-4a9fa02125c3
4  - versionid:f199830a9b206820
5  - paramsid:97d170e1550eee4a
6  */
7
8  /*===== native.h3frompoint (v1) [c8155fac-2fc1-4136-85cd
   -5582e68e7b46] =====*/
9  BEGIN
10 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_595e93c05637805c_f107384622ee8b2c_result`;
11 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_595e93c05637805c_f107384622ee8b2c_result`
12 OPTIONS (
13   expiration_timestamp = TIMESTAMP_ADD(
14     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
15   )
16 )
17 AS
18 SELECT
19   `carto-un-eu.carto`.H3_FROMGEOPOINT(
20     geom, 9
21   ) h3, *
22 FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.accidentes`;
23 END;
24
25 /*===== native.groupby (v1) [4779dff1-8f20-473b-8871-
   b750c99b1822] =====*/
26 BEGIN
27 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_595e93c05637805c_2ace5729ce7ccb1f_result`;
28 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_595e93c05637805c_2ace5729ce7ccb1f_result`
29 OPTIONS (
30   expiration_timestamp = TIMESTAMP_ADD(
31     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
32   )
33 )
34 AS
35 SELECT h3,
36   COUNT(num_expediente) num_expediente_count
37 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_595e93c05637805c_f107384622ee8b2c_result`
38 GROUP BY h3;
39 END;
40
41 /*===== native.renamecolumn (v1) [486d99e7-0f45-47b1-85c0-9
   f6cf2155666] =====*/
42 BEGIN
43 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.

```

```

workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_595e93c05637805c_d72616ffe9572f1b_result`;
44 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_595e93c05637805c_d72616ffe9572f1b_result`
45 OPTIONS (
46   expiration_timestamp = TIMESTAMP_ADD(
47     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
48   )
49 )
50 AS
51 SELECT * EXCEPT (num_expediente_count),
52   num_expediente_count AS volumen_total_accidentes
53 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_595e93c05637805c_2ace5729ce7ccb1f_result`;
54 END;
55
56 /*===== native.getisord (v1) [ccc3745b-59bd-4d56-9f70-7
e3f34d57e00] =====*/
57 BEGIN
58 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_595e93c05637805c_76d28c3461645342_result`;
59 BEGIN
60 DECLARE grid_type STRING;
61 DECLARE grid_resolution INT64;
62
63 CALL `carto-un-eu.carto`.__CHECK_GRID_INDEX_COLUMN(
64   'SELECT * FROM `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_595e93c05637805c_d72616ffe9572f1b_result`',
65   'h3',
66   grid_type,
67   grid_resolution
68 );
69
70 IF grid_type = 'quadbin' THEN
71   CALL `carto-un-eu.carto`.GETIS_ORD_QUADBIN_TABLE(
72     'SELECT * FROM `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_595e93c05637805c_d72616ffe9572f1b_result`',
73     'carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_595e93c05637805c_76d28c3461645342_result',
74     'h3',
75     'volumen_total_accidentes',
76     1,
77     'uniform'
78   );
79 ELSEIF grid_type = 'h3' THEN
80   CALL `carto-un-eu.carto`.GETIS_ORD_H3_TABLE(
81     'SELECT * FROM `carto-dw-ac-t872o53f.
workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_595e93c05637805c_d72616ffe9572f1b_result`',
82     'carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_595e93c05637805c_76d28c3461645342_result',
83     'h3',
84     'volumen_total_accidentes',

```

```

85         1,
86         'uniform'
87     );
88 ELSE
89     RAISE USING MESSAGE = 'Invalid spatial index column, please select a
        column that contains h3 or quadbin indexes.';
90 END IF;
91
92 END;
93 END;
94
95 /*===== native.h3boundary (v1) [1a448d71-b4f8-4695-9b50-9866
        bb559ebd] =====*/
96 BEGIN
97 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
        workflows_temp_jorgekk22_3000e6c3.
        WORKFLOW_595e93c05637805c_27e3f016ecdb8e59_result`;
98 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
        workflows_temp_jorgekk22_3000e6c3.
        WORKFLOW_595e93c05637805c_27e3f016ecdb8e59_result`
99 OPTIONS (
100     expiration_timestamp = TIMESTAMP_ADD(
101         CURRENT_TIMESTAMP(), INTERVAL 30 DAY
102     )
103 )
104 AS
105 SELECT
106     `carto-un-eu.carto`.H3_BOUNDARY(
107         index
108     ) index_geo, *
109 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
        WORKFLOW_595e93c05637805c_76d28c3461645342_result`;
110 END;
111
112 /*===== native.saveastable (v1) [ee8e3462-2a48-4493-aa4b-1
        ba1e6d50264] =====*/
113 BEGIN
114 DECLARE __destination STRING DEFAULT 'carto-dw-ac-t872o53f.
        private_jorgekk22_3000e6c3.Getis_Ord';
115 BEGIN
116 EXECUTE IMMEDIATE
117 REPLACE(
118     '''DROP TABLE IF EXISTS `####`''',
119     '####',
120     __destination
121 );
122 EXECUTE IMMEDIATE
123 REPLACE(
124     '''CREATE TABLE `####`
125     CLONE `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
        WORKFLOW_595e93c05637805c_27e3f016ecdb8e59_result`''',
126     '####',
127     __destination
128 );
129 END;
130 END;
131

```

```

132 /*===== native.localmoransi (v1) [a6e9387f-5b6e-43a5-9d79-
      f5132dd67ce6] =====*/
133 BEGIN
134 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
      workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_595e93c05637805c_331e7ee7b418a83f_result`;
135 BEGIN
136 DECLARE grid_type STRING;
137 DECLARE grid_resolution INT64;
138
139 CALL `carto-un-eu.carto`.__CHECK_GRID_INDEX_COLUMN(
140 'SELECT * FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_595e93c05637805c_d72616ffe9572f1b_result`,
141 'h3',
142 grid_type,
143 grid_resolution
144 );
145
146 IF grid_type = 'quadbin' THEN
147 CALL `carto-un-eu.carto`.LOCAL_MORANS_I_QUADBIN_TABLE(
148 'carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_595e93c05637805c_d72616ffe9572f1b_result',
149 '`carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_595e93c05637805c_331e7ee7b418a83f_result`,
150 'h3',
151 'volumen_total_accidentes',
152 1,
153 'uniform',
154 99
155 );
156 ELSEIF grid_type = 'h3' THEN
157 CALL `carto-un-eu.carto`.LOCAL_MORANS_I_H3_TABLE(
158 'carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_595e93c05637805c_d72616ffe9572f1b_result',
159 '`carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_595e93c05637805c_331e7ee7b418a83f_result`,
160 'h3',
161 'volumen_total_accidentes',
162 1,
163 'uniform',
164 99
165 );
166 ELSE
167 RAISE USING MESSAGE = 'Invalid spatial index column, please select a
      column that contains h3 or quadbin indexes.';
168 END IF;
169
170 END;
171 END;
172
173 /*===== native.h3boundary (v1) [1805ac68-67ef-4212-835f-1
      f0b1291817f] =====*/
174 BEGIN
175 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
      workflows_temp_jorgekk22_3000e6c3.
      WORKFLOW_595e93c05637805c_3836c024e838d2b3_result`;
176 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.

```

```

workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_595e93c05637805c_3836c024e838d2b3_result`
177 OPTIONS (
178   expiration_timestamp = TIMESTAMP_ADD(
179     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
180   )
181 )
182 AS
183 SELECT
184   `carto-un-eu.carto`.H3_BOUNDARY(
185     index
186   ) index_geo, *
187 FROM `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_595e93c05637805c_331e7ee7b418a83f_result`;
188 END;
189
190 /*===== native.saveastable (v1) [0c420bca-2ad8-413c
   -8007-76892fd5f6fc] =====*/
191 BEGIN
192 DECLARE __destination STRING DEFAULT `carto-dw-ac-t872o53f.
   private_jorgekk22_3000e6c3.Local_Morans_I`;
193 BEGIN
194 EXECUTE IMMEDIATE
195 REPLACE(
196   '''DROP TABLE IF EXISTS `####`'',
197   '####',
198   __destination
199 );
200 EXECUTE IMMEDIATE
201 REPLACE(
202   '''CREATE TABLE `####`
203   CLONE `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_595e93c05637805c_3836c024e838d2b3_result`'',
204   '####',
205   __destination
206 );
207 END;
208 END;

```

Listing A.6: SQL del workflow de análisis LISA (Getis-Ord y Local Moran's I).

Workflow de Generación de Polígonos de Clústeres DBSCAN

```

1  /*
2  Code generated by Carto Workflows Engine (RUN)
3  - workflowid:3cb90fdd-7a0b-4afa-b760-e9f7470f8d67
4  - versionid:a76dc1c799d87eb0
5  - paramsid:97d170e1550eee4a
6  */
7
8  /*===== native.clusterdbscan (v1) [e8c2ef61-5a5e-4e32-a54d-4
   fb5657e98a9] =====*/
9  BEGIN
10 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_3cd3b513dc04af3c_55c1b3f7d4d377f6_result`;
11 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_3cd3b513dc04af3c_55c1b3f7d4d377f6_result`
12 OPTIONS (
13   expiration_timestamp = TIMESTAMP_ADD(
14     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
15   )
16 )
17 AS
18 SELECT *,
19   ST_CLUSTERDBSCAN(
20     geom,
21     15,
22     25
23   )
24 OVER () AS cluster
25 FROM `carto-dw-ac-t872o53f.private_jorgekk22_3000e6c3.accidentes`;
26 END;
27
28 /*===== native.customsql (v2.0.0) [fc1a70d3-5f90-486b-9dde-
   c4ce8dd4d288] =====*/
29 BEGIN
30 DROP TABLE IF EXISTS `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_3cd3b513dc04af3c_82745b97b47d19dc_result`;
31 CREATE OR REPLACE TABLE `carto-dw-ac-t872o53f.
   workflows_temp_jorgekk22_3000e6c3.
   WORKFLOW_3cd3b513dc04af3c_82745b97b47d19dc_result`
32 OPTIONS (
33   expiration_timestamp = TIMESTAMP_ADD(
34     CURRENT_TIMESTAMP(), INTERVAL 30 DAY
35   )
36 )
37 AS
38
39
40 WITH
41
42   clustered_points AS (
43     SELECT
44       *
45     FROM

```

```

46     `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3.
WORKFLOW_3cd3b513dc04af3c_55c1b3f7d4d377f6_result`
47     WHERE
48         cluster IS NOT NULL
49         AND ST_GEOMETRYTYPE(geom) = 'ST_Point'
50     ),
51
52
53     cluster_polygons AS (
54         SELECT
55             cluster,
56
57             COUNT(*) AS num_accidentes,
58
59
60             COUNTIF(tipo_accidente_clasificado = 'Colisión doble') AS
count_colision_doble,
61             COUNTIF(tipo_accidente_clasificado = 'Alcance') AS count_alcance,
62             COUNTIF(tipo_accidente_clasificado = 'Atropello a persona') AS
count_atropello,
63             COUNTIF(tipo_accidente_clasificado = 'Choque contra obstáculo') AS
count_obstaculo,
64
65
66             COUNTIF(estado_meteorologico = 'Lluvia intensa') AS count_lluvia,
67             COUNTIF(estado_meteorologico = 'Nublado') AS count_nublado,
68
69
70             ST_CONVEXHULL(ST_UNION_AGG(geom)) AS geom
71     FROM
72         clustered_points
73     GROUP BY
74         cluster
75     HAVING
76         COUNT(*) > 2
77     )
78
79
80     SELECT
81         *
82     FROM
83         cluster_polygons;
84 END;
85
86 /*===== native.saveastable (v1) [bc1029fc-a6a6-474e-bfc6-6
b52c5f57c16] =====*/
87 BEGIN
88 DECLARE __destination STRING DEFAULT `carto-dw-ac-t872o53f.
private_jorgekk22_3000e6c3.dbscan_intersecciones_criticas`;
89 BEGIN
90 EXECUTE IMMEDIATE
91 REPLACE(
92     '''DROP TABLE IF EXISTS `####`''',
93     '####',
94     __destination
95 );
96 EXECUTE IMMEDIATE

```

```
97 REPLACE (  
98   '''CREATE TABLE `####`  
99   CLONE `carto-dw-ac-t872o53f.workflows_temp_jorgekk22_3000e6c3`  
100     WORKFLOW_3cd3b513dc04af3c_82745b97b47d19dc_result`''',  
101   __destination  
102 );  
103 END;  
104 END;
```

Listing A.7: SQL para la creación y enriquecimiento de polígonos de clústeres DBSCAN.

A.3 Campos Calculados de Tableau

A continuación, se detallan los campos calculados más relevantes implementados en Tableau. Se han omitido campos intermedios o de prueba para mayor claridad.

Diferencia entre Cálculos Normales y Expresiones de Nivel de Detalle (LOD)

En Tableau, un cálculo normal opera sobre la granularidad de datos presente en la vista actual. Sin embargo, las **Expresiones de Nivel de Detalle (LODs)**, como `FIXED`, permiten realizar cálculos en un nivel de granularidad diferente. En este trabajo, se utiliza principalmente `{FIXED [num_expediente] : ...}` para calcular un valor a nivel de accidente único y aplicar ese valor a todas las filas (implicados) que pertenecen a ese mismo accidente.

1. Métricas Fundamentales y KPIs

c_Total_Accidentes

Contar el número total de accidentes únicos.

```
1 COUNTD([num_expediente])
```

c_Total_Implicados

Contar el número total de personas implicadas.

```
1 COUNT([num_expediente])
```

c_Total_Conductores

Contar el número total de conductores implicados.

```
1 SUM(IF [tipo_persona] = "Conductor" THEN 1 ELSE 0 END)
```

c_Total_Fallecidos

Contar el número total de implicados fallecidos (KPI).

```
1 SUM(IF [lesividad_clasificada] = "FALLECIDOS" THEN 1 ELSE 0 END)
```

c_Total_Conductores_Positivos

Contar el total de conductores con resultado positivo en alcohol o drogas (KPI).

```
1 SUM(  
2   IF [Tipo Persona] = "Conductor"  
3     AND ([Positiva Alcohol] = "S" OR [Positiva Droga] = 1)  
4   THEN 1 ELSE 0 END  
5 )
```

Pct_Conductores_Positivos_Alcohol

Calcular el porcentaje de conductores que dieron positivo en alcohol.

```
1 (SUM(IF [Tipo Persona] = "Conductor" AND [Positiva Alcohol] = "S" THEN 1  
   ELSE 0 END)  
2 /  
3 SUM(IF [Tipo Persona] = "Conductor" THEN 1 ELSE 0 END))*100
```

Pct_Conductores_Positivos_Droga

Calcular el porcentaje de conductores que dieron positivo en drogas.

```

1 (SUM(IF [Tipo Persona] = "Conductor" AND [Positiva Droga] = 1 THEN 1 ELSE 0
    END)
2 /
3 SUM(IF [Tipo Persona] = "Conductor" THEN 1 ELSE 0 END))*100

```

2. Campos de Categorización de Gravedad (LODs)

c_LOD_MaximaLesividad_Orden

Asigna un valor numérico a la lesividad máxima de un accidente (LOD).

```

1 {FIXED [Num Expediente] : MAX(
2     CASE [Lesividad Clasificada]
3         WHEN "FALLECIDOS" THEN 4
4         WHEN "HERIDOS GRAVES" THEN 3
5         WHEN "HERIDOS LEVES" THEN 2
6         WHEN "SIN ASISTENCIA / ILESOS" THEN 1
7         ELSE 0
8     END
9 )}

```

c_LOD_MaximaLesividad_Texto

Convierte el orden numérico de la máxima lesividad en una etiqueta de texto descriptiva.

```

1 CASE [c_LOD_MaximaLesividad_Orden.txt]
2     WHEN 4 THEN "FALLECIDOS (accidente)"
3     WHEN 3 THEN "HERIDOS GRAVES (accidente)"
4     WHEN 2 THEN "HERIDOS LEVES (accidente)"
5     WHEN 1 THEN "SOLO ILESOS (accidente)"
6     ELSE "DESCONOCIDA / OTROS (accidente)"
7 END

```

3. Campos para Análisis de Riesgo y Consecuencias

Pct_Accidentes_Graves_o_Fatales

Utilizado para generar la ordenación por gravedad en la visualización “Distribución de Accidentes por Máxima Gravedad (según estado meteorológico)”.

```

1 COUNTD(IF [c_Accident_MaximaLesividadTexto] = "FALLECIDOS (accidente)" OR [
    c_Accident_MaximaLesividadTexto] = "HERIDOS GRAVES (accidente)" THEN [
    Num Expediente] END)
2 /
3 COUNTD(IF NOT ISNULL([c_Accident_MaximaLesividadTexto]) AND [
    c_Accident_MaximaLesividadTexto] <> "DESCONOCIDA / OTROS (accidente)"
    THEN [Num Expediente] END)

```

Pct_Ocupantes_Graves_o_Fatales

Utilizado para generar la ordenación por gravedad en la visualización “Perfil de Lesividad de Ocupantes por Tipo de Vehículo”.

```

1 SUM(IF [Lesividad Clasificada] = "FALLECIDOS" OR [Lesividad Clasificada] =
    "HERIDOS GRAVES" THEN 1 ELSE 0 END)
2 /
3 SUM(1) // Esto es el total de implicados para esa fila (tipo_vehiculo)

```

c_LOD_Conductor_Positivo

Marca cada accidente (1/0) si tuvo al menos un conductor positivo. Es un campo auxiliar de tipo LOD para poder filtrar o categorizar accidentes completos.

```
1 {FIXED [num_expediente] : MAX(  
2     IF [tipo_persona] = "Conductor"  
3         AND ([positiva_alcohol] = "S" OR [positiva_droga] = 1)  
4     THEN 1  
5     ELSE 0  
6     END  
7 )}
```

c_Total_Fallecidos_Conductor_Positivo

Cuenta los fallecidos en accidentes donde un conductor dio positivo, utilizando el campo LOD anterior.

```
1 SUM(  
2     IF [c_LOD_Conductor_Positivo] = 1 AND [Lesividad Clasificada] = "  
3     FALLECIDOS" THEN 1  
4     ELSE 0  
5     END  
6 )
```

c_Estado_Positivo_Conductor

Categoriza a los conductores según el tipo de sustancia positiva.

```
1 IF [tipo_persona] = "Conductor" THEN  
2     IF [positiva_alcohol] = "S" AND [positiva_droga] = 1 THEN "Alcohol y  
3     Drogas"  
4     ELSEIF [positiva_alcohol] = "S" THEN "Solo Alcohol"  
5     ELSEIF [positiva_droga] = 1 THEN "Solo Drogas"  
6     ELSE "Negativo/No Consta"  
7     END  
8 ELSE NULL  
9 END
```

Diccionario de Variables

Este apéndice detalla la estructura y el contenido de los principales ficheros de datos utilizados en este trabajo.

Fuente: Portal de Datos Abiertos del Ayuntamiento de Madrid [Ayu25].

B.1 Ficheros de Datos de Accidentalidad

Para evitar la repetición y mostrar la evolución de los datos, la estructura de los conjuntos de datos de accidentalidad generados en el proyecto se presenta en la siguiente tabla unificada.

- **accidentalidad_sin_distrito.geojson:** El fichero base generado por R. Su estructura incluye todas las columnas listadas a continuación, **excepto** la columna **distrito** (marcada con *).
- **accidentalidad.geojson:** Generada en CARTO al añadir la información del distrito. Su estructura incluye **todas las columnas** de la tabla.
- **accidentes.geojson:** La vista agregada por evento. Su estructura incluye **únicamente** las columnas marcadas con el símbolo ('+').

Cuadro B.1: Estructura Unificada de Columnas de Datos de Accidentalidad

Nombre Columna	Descripción	Valores Esperados
num_expediente [†]	Identificador único del accidente.	Texto / Factor
fecha [†]	Fecha completa del accidente.	Fecha (AAAA-MM-DD)
tipo_accidente_clasificado [†]	Clasificación agrupada del tipo de accidente.	Texto / Factor
estado_meteorologico [†]	Condición climatológica del momento.	Texto / Factor
anno [†]	Año del accidente.	Numérico (e.g., 2019)
mes [†]	Nombre del mes del accidente.	Texto (e.g., "enero")
dia_mes [†]	Día del mes del accidente.	Numérico (1-31)
dia_semana [†]	Nombre del día de la semana.	Texto (e.g., "lunes")

Cuadro B.1: Continuación del Cuadro B.1

Nombre Columna	Descripción	Valores Esperados
horas [†]	Hora del accidente (rango 0-23).	Numérico (0-23)
hora_rango [†]	Franja horaria del día.	Texto / Factor
tipo_vehiculo_clasificado	Clasificación del vehículo implicado.	Texto / Factor
tipo_persona	Rol de la persona implicada.	Texto / Factor
rango_edad	Tramo de edad de la persona.	Texto / Factor ordenado
sexo	Sexo de la persona.	Texto / Factor
lesividad_clasificada	Gravedad de las lesiones de la persona.	Texto / Factor ordenado
positiva_alcohol	Positivo en test de alcoholemia.	Texto / Factor ("S" o "N")
positiva_droga	Positivo en test de drogas.	Texto / Factor ("1" o "0")
geometry [†]	Coordenadas geográficas del accidente.	Punto GeoJSON (WGS84)
distrito ^{*†}	Columna Enriquecida. Distrito donde ocurre el accidente.	Texto / Factor

* Columna añadida en CARTO para crear la tabla *accidentalidad.geojson*. No está presente en *accidentalidad_sin_distrito.geojson*.

† Columnas presentes en la tabla *agregada accidentes.geojson*.

Detalle de las Nuevas Columnas de Clasificación

Tipo de Accidente Clasificado

Clasificación basada en la columna `tipo_accidente` original.

- **Colisión doble:** Agrupa "Colisión frontal", "Colisión fronto-lateral", "Colisión lateral".
- **Colisión múltiple:** Corresponde a "Colisión múltiple".
- **Alcance:** Corresponde a "Alcance".
- **Choque contra obstáculo:** Corresponde a "Choque contra obstáculo fijo".
- **Atropello a persona:** Corresponde a "Atropello a persona".
- **Otras causas:** Agrupa "Vuelco", "Caída", "Atropello a animal", "Despeñamiento", etc.

Tipo de Vehículo Clasificado

Clasificación basada en la columna `tipo_vehiculo` original.

- **Motocicleta:** Agrupa todas las motocicletas.
- **Ciclomotor:** Agrupa todos los ciclomotores.
- **Bicicleta:** Agrupa “Bicicleta”, “Ciclo”, “Bicicleta EPAC”.
- **Patinete:** Agrupa “Patinete” y “Patinete no eléctrico”.
- **Camión:** Agrupa “Camión rígido”, “Tractocamión”, “Vehículo articulado”.
- **Autobús:** Agrupa “Autobús”, “Autobús articulado”, “Autobus EMT”, “Microbús”.
- **Turismo/Furgoneta:** Agrupa “Turismo”, “Todo terreno”, “Furgoneta”.

Lesividad Clasificada

Clasificación basada en la columna `lesividad` original para resumir la gravedad.

- **FALLECIDOS:** Corresponde a “Fallecido 24 horas”.
- **HERIDOS GRAVES:** Corresponde a “Ingreso superior a 24 horas”.
- **HERIDOS LEVES:** Agrupa varios tipos de atención sanitaria sin ingreso prolongado.
- **SIN ASISTENCIA / ILESOS:** Corresponde a “Sin asistencia sanitaria”.
- **LESIVIDAD DESCONOCIDA:** Agrupa valores nulos o desconocidos.

B.2 Fichero: `distritos.geojson`

Descripción: Contiene las geometrías poligonales de los distritos de Madrid.

Cuadro B.2: Estructura de Columnas del Fichero `distritos.geojson`

Nombre columna	Descripción	Valores esperados
<code>distrito</code>	Nombre oficial del distrito municipal.	Texto / Factor
<code>geometry</code>	Geometría del polígono del distrito.	Polígono GeoJSON (WGS84)

B.3 Fichero: hospitales.geojson

Descripción: Ubicación puntual de los principales hospitales en la Comunidad de Madrid.

Cuadro B.3: Estructura de Columnas del Fichero hospitales.geojson

Nombre columna	Descripción	Valores esperados
NOMBRE	Nombre oficial del centro hospitalario.	Texto
geometry	Coordenadas geográficas del hospital.	Punto GeoJSON (WGS84)

B.4 Fichero: radares_fijos.geojson

Descripción: Contiene la ubicación puntual de los radares de velocidad de tipo “Fijo”.

Cuadro B.4: Estructura de Columnas del Fichero radares_fijos.geojson

Nombre columna	Descripción	Valores esperados
Velocidad_limite	Límite de velocidad (en km/h).	Numérico
geometry	Coordenadas geográficas del radar.	Punto GeoJSON (WGS84)

B.5 Fichero: `camaras.geojson`

Descripción: Fichero unificado con la ubicación de distintos tipos de cámaras de tráfico.

Cuadro B.5: Estructura de Columnas del Fichero `camaras.geojson`

Nombre columna	Descripción	Valores esperados
<code>tipo</code>	Nueva columna. Clasificación del tipo de cámara.	Texto / Factor (“CCTV”, “ZBE”, “ZBEDEP”)
<code>geometry</code>	Coordenadas geográficas de la cámara.	Punto GeoJSON (WGS84)

Visualizaciones Complementarias

Este Apéndice contiene visualizaciones adicionales que complementan los resultados presentados en el cuerpo principal del documento.

C.1 Ejemplos de Proyecciones Cartográficas

A continuación se ilustran dos proyecciones cartográficas clásicas que ejemplifican el compromiso fundamental entre preservar ángulos y preservar áreas.



Figura C.1: La proyección de Mercator, un ejemplo de proyección **conforme**. Preserva los ángulos y las formas locales, pero distorsiona masivamente las áreas. Obsérvese cómo Groenlandia (2.16 millones de km²) parece tener un tamaño similar al de África (30.37 millones de km²), cuando en realidad África es 14 veces más grande.




Figura C.2: La proyección de Gall-Peters, un ejemplo de proyección **equivalente** (iso-areal). Preserva la proporción correcta de las áreas, mostrando el tamaño real de los continentes entre sí. Sin embargo, para lograrlo, distorsiona notablemente sus formas, especialmente en las zonas ecuatoriales y polares, que aparecen estiradas vertical u horizontalmente.